

UỶ BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

SUY DIỄN CHẨN ĐOÁN VIÊM PHỔI

DỰA TRÊN MẠNG BAYESIAN

Mã số đề tài: SV2024-90

Thuộc nhóm ngành khoa học:	Kỹ thuật
Chủ nhiệm đề tài:	Trần Vĩnh Huy
Thành viên tham gia:	Trần Vĩnh Huy Nguyễn Minh Nhựt Trần Gia Bảo Trương Quang Long
Giảng viên hướng dẫn:	TS. Đỗ Như Tài

ỦY BAN NHÂN DÂN
THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

SUY DIỄN CHUẨN ĐOÁN VIÊM PHỔI
DỰA TRÊN MẠNG BAYESIAN
Mã số đề tài: SV2024-90

Xác nhận của
Chủ tịch hội đồng nghiệm thu
(ký, họ tên)

Chủ nhiệm đề tài
(ký, họ tên)

Thành phố Hồ Chí Minh, 04/2025

MỤC LỤC

MỤC LỤC	i
DANH MỤC BẢNG BIỂU, HÌNH ẢNH.....	iii
DANH MỤC CHỮ VIẾT TẮT.....	iv
BẢN TÓM TẮT ĐỀ TÀI	v
PHẦN MỞ ĐẦU	1
1. Lý do chọn đề tài.....	1
2. Lịch sử nghiên cứu vấn đề	1
3. Mục đích và nhiệm vụ nghiên cứu.....	2
4. Đối tượng và phạm vi nghiên cứu.....	3
5. Phương pháp nghiên cứu.....	4
6. Những đóng góp mới của đề tài.....	5
7. Cấu trúc của đề tài.....	6
PHẦN NỘI DUNG.....	7
CHƯƠNG 1: GIỚI THIỆU VẤN ĐỀ NGHIÊN CỨU.....	7
1.1. Nhu cầu thực tế.....	7
1.2. Tiếp cận Bayesian để cải thiện chẩn đoán viêm phổi.....	8
1.3. Tại sao áp dụng văn bản y khoa vào chẩn đoán viêm phổi là cần thiết ?.....	9
1.4. Hạn chế của mô hình Bayesian	9
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	11
2.1. Giới thiệu chung về mô hình mạng Bayesian	11
2.2. Ví dụ minh họa về cách hoạt động Bayesian Network	12
2.3. Mạng Feed-Forward Neural Networks (FFNN).....	18
2.3.1. Cơ sở lý thuyết.....	18
2.3.2. Mô hình Mạng Nơ-ron Lan Truyền Tiến Tuyến Tính (Feedforward Neural Network - FFNN) theo Kiến trúc Tuần Tự (Sequential).....	19
2.4. Phương pháp giải thích mô hình máy học (XAI) LIME và SHAP	21
2.4.1. Giới thiệu	21
2.4.2. LIME.....	21
2.4.3. SHAP	22

2.4.4. Quy trình thực hiện và ý nghĩa đóng góp	23
CHƯƠNG 3: MÔ HÌNH ĐỀ XUẤT.....	25
3.1. Mạng Bayesian theo kiến thức chuyên gia	25
3.2. Mạng Bayesian Baseline	27
3.3. Mô hình Embedding văn bản	30
3.4. Mô hình Neural Network	31
3.5. Mạng Neural kết hợp mạng Bayesian	33
CHƯƠNG 4: THỰC NGHIỆM VÀ BÌNH LUẬN	36
4.1. Dữ liệu thực nghiệm.	36
4.2. Giới thiệu môi trường, dữ liệu và quy trình thực nghiệm	39
4.3. Độ đo đánh giá hiệu suất mô hình	40
4.3.1. ROC-AUC.....	40
4.3.2. AP.....	41
4.4. Thực nghiệm 1: Mô hình Bayesian Baseline Network	42
4.5. Thực nghiệm 2: So sánh BBN với mô hình khác.....	43
4.6. Thực nghiệm 3: Mô hình Neural Network	44
4.7. Thực nghiệm 4: Trích xuất triệu chứng trong văn bản y khoa	46
4.9. Thực nghiệm 6: Kết quả XAI thông qua kỹ thuật LIME	51
4.10. Thực nghiệm 7: Kết quả XAI thông qua kỹ thuật SHAP	56
4.10.1. Pneumonia.....	56
4.10.2. Infection.....	58
4.11. So sánh kết quả thực nghiệm SHAP giữa BlackBox và WhiteBox.....	60
KẾT LUẬN VÀ KHUYẾN NGHỊ.....	63
TÀI LIỆU THAM KHẢO	64

DANH MỤC BẢNG BIỂU, HÌNH ẢNH

Hình 1.1. Biểu đồ số ca nhiễm Covid19 tại Việt Nam giai đoạn tháng 4 - 5/2023...	07
Hình 2.1. Cấu trúc Bayesian Network.....	11
Hình 2.2: Cấu trúc Bayesian Network mẫu.....	14
Bảng 2.3. Tập train.....	14
Bảng 2.4. Tập Test.....	14
Bảng 2.5. Bảng kết luận dự đoán ID 9 và ID 10.....	17
Hình 2.6: Một mẫu Feed-forward Neural Network với 1 lớp hidden (với 3 neurons).....	18
Hình 2.7. Quy trình giải thích mô hình máy học sử dụng LIME và SHAP.....	23
Hình 3.1. Cấu trúc DAG theo kiến thức chuyên gia.....	25
Bảng 3.2. Mô tả các biến trên cấu trúc DAG.....	26
Hình 3.3. Sơ đồ mô hình Bayesian Network Baseline.....	28
Hình 3.4: Quy trình Embedding text với model BioLord2023.....	30
Hình 3.5. Mô hình Neural Network.....	31
Bảng 3.6. Cấu hình input Neural Network (Text2Clinical).....	31
Hình 3.7. Sơ đồ mô hình BN + Neural Network (Text2Clinical).....	33
Hình 3.8. Sơ đồ các mô hình so sánh.....	35
Hình 4.1. Stack Bar Chart SynSum Dataset.....	36
Bảng 4.2: Pneumonia và Infection trong SynSUM Dataset.....	37
Hình 4.3. Mẫu văn bản y khoa không cấu trúc mô tả triệu chứng lâm sàng của bệnh nhân.....	38
Bảng 4.4: Quy trình thực nghiệm.....	39
Bảng 4.5: Kết quả thực nghiệm mô hình BNN.....	42
Bảng 4.6: So sánh mô hình BNN với các mô hình truyền thống.....	43
Bảng 4.7: Kết quả thực nghiệm mô hình Neural Network.....	45
Bảng 4.8: Kết quả thực nghiệm khả năng trích xuất triệu chứng từ text của các thuật toán.....	47
Bảng 4.9: Kết quả thực nghiệm mô hình BN - Neural Network và so sánh các mô hình khác.....	49
Hình 4.10. Kết quả thực nghiệm LIME với chẩn đoán Pneumonia = yes.....	52
Hình 4.11. Kết quả thực nghiệm LIME với chẩn đoán Pneumonia = no.....	53
Hình 4.12. Kết quả thực nghiệm LIME với chẩn đoán Infection = yes.....	54
Hình 4.13. Kết quả thực nghiệm LIME với chẩn đoán Infection = no.....	55
Hình 4.14. Kết quả thực nghiệm SHAP với chẩn đoán của nhãn Pneumonia.....	56
Hình 4.15. Kết quả thực nghiệm SHAP với chẩn đoán của nhãn Infection.....	58
Hình 4.16. Kết quả thực nghiệm SHAP giữa hai mô hình WhiteBox và BlackBox..	60

DANH MỤC CHỮ VIẾT TẮT

AI	Artificial Intelligence
BN	Baseline
NLP	Neuro-linguistic programming
DAG	Directed Acyclic Graph
Pneu	Pneumonia
Inf	Infection
FNN / FFNN	Feedforward Neural Network
NN	Neural Network
ANN	Artificial Neural Networks
ReLU	Rectified Linear Unit
BNN	Bayesian Neural Networks
SVM	Support Vector Machine
COPD	Chronic Obstructive Pulmonary Disease
CPT	Conditional Probability Table
XAI	Explainable AI
LIME	Local Interpretable Model-agnostic Explanations
SHAP	SHapley Additive exPlanations

BẢN TÓM TẮT ĐỀ TÀI

Đề tài “Chẩn đoán viêm phổi qua mạng Bayesian” tập trung vào việc xây dựng một mô hình chẩn đoán bệnh viêm phổi dựa trên phương pháp mạng Bayesian, với mục tiêu hỗ trợ các bác sĩ đưa ra quyết định chính xác và nhanh chóng trong môi trường lâm sàng, đặc biệt là khi nguồn lực về nhân sự hoặc thiết bị còn hạn chế.

Nghiên cứu khai thác ưu điểm của mạng Bayesian trong việc mô hình hóa mối quan hệ xác suất giữa các yếu tố lâm sàng như triệu chứng (sốt, ho, khó thở...), tiền sử bệnh nhân (clinical), và văn bản ghi chú không cấu trúc của bác sĩ và các chẩn đoán y khoa.

Kết quả nghiên cứu cho thấy mô hình baseline đạt độ chính xác trung bình khoảng Pneu (ROC – AUC: 0.98, AP: 0.67) và Inf (ROC – AUC: 0.92, AP: 0.81), thể hiện khả năng suy diễn tốt, đồng thời cung cấp khả năng giải thích mối liên hệ giữa các yếu tố đầu vào và nguy cơ mắc viêm phổi – một ưu điểm nổi bật so với các mô hình học máy khác như mạng nơ-ron hay XGBoost.

Nghiên cứu đề xuất định hướng mở rộng mô hình baseline với dữ liệu viêm phổi có văn bản y khoa của bác sĩ nhằm nâng cao tính tổng quát, đồng thời tích hợp mô hình. Bên cạnh đó, đề tài kiến nghị phát triển các mô hình kết hợp giữa mạng Bayesian và học sâu để vừa đảm bảo hiệu quả dự đoán, vừa duy trì khả năng giải thích rõ ràng – yếu tố quan trọng trong lĩnh vực y học chính xác.

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Trong thời đại hiện đại, trí tuệ nhân tạo và máy tính đã trở thành những công cụ quan trọng trong nhiều lĩnh vực tài chính, xã hội, đặc biệt là y tế. Các mô hình học máy và phương pháp suy diễn đang được ứng dụng rộng rãi nhằm hỗ trợ chẩn đoán và điều trị bệnh một cách chính xác và hiệu quả hơn.

Trong lĩnh vực y học, đặc biệt sau đại dịch Covid-19, chẩn đoán viêm phổi là một vấn đề quan trọng, đòi hỏi sự chính xác cao để đưa ra quyết định điều trị phù hợp. Tuy nhiên, việc chẩn đoán dựa trên dữ liệu lâm sàng thường gặp phải những thách thức như sự không chắc chắn của dữ liệu và tính phức tạp trong mối quan hệ giữa các yếu tố bệnh lý.

Vì vậy, nhóm đã chọn nghiên cứu đề tài "Suy diễn chẩn đoán viêm phổi dựa trên mạng Bayesian" nhằm phát triển một phương pháp giúp hỗ trợ quá trình chẩn đoán một cách có hệ thống và hiệu quả hơn. Mạng Bayesian là một mô hình xác suất mạnh mẽ, có khả năng thể hiện mối quan hệ giữa các biến số y khoa và xử lý tốt sự không chắc chắn trong dữ liệu. Thông qua việc áp dụng phương pháp này, nghiên cứu không chỉ giúp cải thiện độ chính xác trong chẩn đoán viêm phổi mà còn góp phần nâng cao hiệu suất của các hệ thống hỗ trợ quyết định trong y tế.

2. Lịch sử nghiên cứu vấn đề

Việc ứng dụng trí tuệ nhân tạo vào chẩn đoán y khoa đã thu hút sự quan tâm của nhiều nhà nghiên cứu từ cuối thế kỷ 20. Ban đầu, các phương pháp chẩn đoán chủ yếu dựa trên hệ chuyên gia (Expert Systems), trong đó các quy tắc suy diễn được xây dựng thủ công bởi các chuyên gia y tế. Tuy nhiên, phương pháp này gặp nhiều hạn chế do khó khăn trong việc cập nhật và mở rộng tập luật khi có thêm dữ liệu mới. Một số nghiên cứu tiêu biểu có thể kể đến như hệ thống MYCIN [18] được phát triển để chẩn đoán bệnh nhiễm trùng, tuy đạt độ chính xác cao nhưng thiếu khả năng mở rộng và không linh hoạt khi đối mặt với dữ liệu chưa từng gặp.

Vào những năm đầu thế kỷ 21, các phương pháp thống kê và học máy bắt đầu được áp dụng rộng rãi trong y học. Các mô hình như cây quyết định (Decision Trees)

và mạng nơ-ron nhân tạo (Artificial Neural Networks) đã được sử dụng để hỗ trợ chẩn đoán viêm phổi dựa trên dữ liệu lâm sàng và hình ảnh y tế. Nghiên cứu của K. Cios [19] đã áp dụng mạng nơ-ron nhân tạo vào phân loại hình ảnh X-quang phổi, đạt độ chính xác cao hơn so với phương pháp truyền thống. Tuy nhiên, những phương pháp này thường gặp khó khăn trong việc diễn giải kết quả, vì mô hình hoạt động như một "hộp đen" (black box), khiến các bác sĩ khó hiểu được lý do dẫn đến quyết định chẩn đoán.

Nhằm khắc phục những hạn chế trên, các nhà nghiên cứu đã chuyển sang sử dụng mạng Bayesian – một công cụ mạnh mẽ trong suy diễn xác suất. Mạng Bayesian có khả năng mô hình hóa mối quan hệ giữa các yếu tố bệnh lý, cho phép bác sĩ không chỉ dự đoán nguy cơ mắc bệnh mà còn hiểu được tác động của từng yếu tố trong quá trình chẩn đoán. Nghiên cứu của Lucas [20] đã chứng minh rằng mạng Bayesian có thể cung cấp các quyết định chẩn đoán chính xác hơn so với các mô hình dựa trên cây quyết định. Tuy nhiên, một nhược điểm của mạng Bayesian là yêu cầu lượng lớn dữ liệu để học chính xác các mối quan hệ giữa các biến, và việc học cấu trúc (Structure Learning) của mô hình vẫn là một thách thức.

Nhìn chung, mặc dù AI đã đạt được nhiều thành tựu trong chẩn đoán viêm phổi, nhưng vẫn tồn tại nhiều thách thức. Các hệ thống AI cần được thiết kế sao cho có thể diễn giải dễ dàng, đáng tin cậy và phù hợp với thực tiễn lâm sàng. Việc kết hợp nhiều phương pháp khác nhau, chẳng hạn như mạng Bayesian với các mô hình học sâu, có thể giúp cải thiện độ chính xác và tính minh bạch trong chẩn đoán y khoa.

3. Mục đích và nhiệm vụ nghiên cứu

Mục đích chính của nghiên cứu này là phát triển và áp dụng các phương pháp cải tiến mạng Bayesian nhằm cải thiện hiệu suất và chính xác của các hệ thống dựa trên tối ưu quan hệ giữa các biến và văn bản y khoa trong lĩnh vực trí tuệ nhân tạo và học máy. Mục tiêu cuối cùng là tạo ra các hệ thống thông minh linh hoạt và hiệu quả hơn trong việc đưa ra quyết định và dự đoán trong các ứng dụng thực tiễn.

Về nhiệm vụ nghiên cứu :

- Phân tích và đánh giá các phương pháp hiện có: Nghiên cứu sẽ tiến hành phân tích các phương pháp chẩn đoán viêm phổi hiện nay, đặc biệt là các phương pháp sử dụng trí tuệ nhân tạo và mạng Bayesian. Điều này bao gồm việc đánh giá hiệu suất của các mô hình suy diễn hiện có, từ các hệ chuyên gia dựa trên luật đến các mô hình học máy thống kê, nhằm xác định ưu điểm và hạn chế của từng phương pháp.
- Phát triển phương pháp mới: Dựa trên kết quả phân tích, nghiên cứu sẽ tập trung vào việc cải tiến hoặc phát triển một phương pháp suy diễn chẩn đoán mới dựa trên mạng Bayesian. Điều này có thể bao gồm tối ưu hóa cấu trúc mạng, cải thiện phương pháp học tham số và tích hợp các kỹ thuật học máy hiện đại để nâng cao độ chính xác trong chẩn đoán viêm phổi.
- Thử nghiệm và đánh giá: Sau khi phát triển mô hình mới, nghiên cứu sẽ tiến hành thử nghiệm trên các tập dữ liệu lâm sàng thực tế để đánh giá hiệu suất của mô hình. Các tiêu chí đánh giá có thể bao gồm độ chính xác, độ nhạy, độ đặc hiệu và khả năng giải thích kết quả. So sánh với các phương pháp hiện có sẽ giúp xác định tính ưu việt của phương pháp đề xuất.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu trong đề tài này bao gồm các hệ thống suy diễn và chẩn đoán y khoa dựa trên mạng Bayesian. Cụ thể, nghiên cứu tập trung vào:

- Hệ thống hỗ trợ quyết định trong y tế, đặc biệt là các hệ thống chẩn đoán viêm phổi dựa trên dữ liệu lâm sàng và hình ảnh y tế.
- Các mô hình mạng Bayesian được sử dụng để mô hình hóa mối quan hệ giữa các yếu tố bệnh lý, giúp suy diễn xác suất mắc bệnh dựa trên thông tin đầu vào.
- Các thuật toán học máy và thống kê hỗ trợ tối ưu hóa mạng Bayesian nhằm nâng cao độ chính xác và tính khả dụng trong thực tiễn.

Phạm vi nghiên cứu được xác định bởi các khía cạnh:

- Phạm vi địa lý: Nghiên cứu không giới hạn về địa lý và có thể áp dụng cho các

hệ thống chẩn đoán viêm phổi trên toàn thế giới, tùy thuộc vào dữ liệu và điều kiện y tế cụ thể của từng quốc gia.

- Phạm vi thời gian: Nghiên cứu tập trung vào việc phát triển và cải tiến các phương pháp suy diễn hiện đại, nhưng vẫn có thể áp dụng cho các hệ thống y tế truyền thống nếu phù hợp.
- Phạm vi ứng dụng: Đề tài hướng đến việc ứng dụng trong chẩn đoán và hỗ trợ quyết định lâm sàng, giúp bác sĩ phân tích dữ liệu bệnh nhân một cách hiệu quả hơn. Ngoài ra, phương pháp này có thể mở rộng sang các lĩnh vực khác như dịch tễ học và phân tích dữ liệu y tế.

5. Phương pháp nghiên cứu

Về phương pháp nghiên cứu, đề tài nghiên về “Suy diễn chẩn đoán viêm phổi dựa trên mạng Bayesian” sẽ được tiếp cận trên các cơ sở sau :

- Tổng quan lý thuyết:
 - Tiến hành nghiên cứu các tài liệu, bài báo khoa học và công trình đã công bố liên quan đến mạng Bayes và ứng dụng của chúng trong chẩn đoán y khoa.
 - Tìm hiểu các phương pháp suy diễn xác suất, học tham số và học cấu trúc trong mạng Bayesian, đặc biệt trong bối cảnh chẩn đoán viêm phổi.
 - Đánh giá các thách thức hiện tại trong việc áp dụng mạng Bayesian vào hệ thống hỗ trợ chẩn đoán.
- Phát triển phương pháp:
 - Đề xuất mô hình mạng Bayesian phù hợp để suy diễn chẩn đoán viêm phổi dựa trên dữ liệu lâm sàng.
 - Ứng dụng các thuật toán học tham số (Parameter Learning) và học cấu trúc (Structure Learning) để tối ưu hóa mô hình.
 - Kết hợp các mô hình mạng Nơ-ron, XGBoost.. xử lý text kết hợp mạng

Bayesian để chẩn đoán nhân viêm phổi và nhiễm trùng.

- Kết hợp các kỹ thuật cải tiến từ học máy và thống kê nhằm nâng cao độ chính xác và hiệu suất của hệ thống.
- Kết hợp các kỹ thuật XAI như LIME – SHAP để diễn giải chẩn đoán của mô hình.
- Thử nghiệm và đánh giá
 - Áp dụng mô hình đề xuất trên các tập dữ liệu thực tế từ hồ sơ bệnh nhân hoặc các bộ dữ liệu y tế công khai.
 - Đánh giá hiệu suất của mô hình thông qua các chỉ số như AUC-ROC và Precision Recall (AP).
- So sánh và phân tích kết quả
 - So sánh mô hình đề xuất với các phương pháp chẩn đoán hiện có, các mô hình học máy khác (như cây quyết định, mạng nơ-ron).
 - Phân tích ưu điểm và hạn chế của phương pháp đề xuất dựa trên kết quả thử nghiệm.
- Phân tích và tổng hợp kết quả
 - Tổng hợp các kết quả thu được để đánh giá tính khả thi của mô hình trong thực tiễn.
 - Đề xuất hướng phát triển trong tương lai, bao gồm việc cải tiến thuật toán, mở rộng ứng dụng cho các bệnh lý khác và triển khai mô hình vào hệ thống hỗ trợ quyết định lâm sàng.

6. Những đóng góp mới của đề tài

Đề tài này mang lại một số đóng góp trong nghiên cứu và ứng dụng mạng Bayesian vào chẩn đoán viêm phổi, đặc biệt trong việc xử lý dữ liệu y khoa và suy diễn dựa trên văn bản lâm sàng. Cụ thể, các đóng góp bao gồm:

1. Phát triển phương pháp suy diễn chẩn đoán viêm phổi dựa trên mạng

Bayesian, giúp nâng cao độ chính xác và hiệu quả trong hỗ trợ quyết định lâm sàng.

2. Cải tiến các kỹ thuật học tham số và học cấu trúc trong mạng Bayesian, giúp tối ưu hóa mô hình và nâng cao khả năng suy diễn từ dữ liệu bệnh nhân.
3. Đóng góp vào nền tảng lý thuyết về mạng Bayesian trong lĩnh vực y tế, cung cấp cơ sở khoa học cho các nghiên cứu tiếp theo trong chẩn đoán bệnh sử dụng trí tuệ nhân tạo.
4. Xử lý văn bản y khoa và trích xuất thông tin từ hồ sơ bệnh án
5. Xây dựng mô hình trích xuất đặc trưng từ văn bản y khoa để làm đầu vào cho mạng Bayesian.
6. Kết hợp dữ liệu văn bản và dữ liệu lâm sàng (chẳng hạn như kết quả xét nghiệm) để cải thiện độ chính xác trong chẩn đoán.
7. Sử dụng các kỹ thuật LIME – SHAP để suy diễn chẩn đoán.

7. Cấu trúc của đề tài

Ngoài phần mở đầu, kết luận, danh mục tài liệu tham khảo và phụ lục, đề tài gồm có 5 chương:

Chương 1: Giới thiệu vấn đề nghiên cứu

Chương 2: Cơ sở lý thuyết

Chương 3: Mô hình đề xuất

Chương 4: Kết quả thực nghiệm


PHẦN NỘI DUNG

CHƯƠNG 1: GIỚI THIỆU VẤN ĐỀ NGHIÊN CỨU

1.1. Nhu cầu thực tế

Viêm phổi là một bệnh lý nguy hiểm, có thể gây tử vong nếu không được phát hiện và điều trị kịp thời, đặc biệt ở trẻ em, người già và những bệnh nhân có hệ miễn dịch suy yếu. Quá trình chẩn đoán viêm phổi hiện nay chủ yếu dựa trên kết hợp triệu chứng lâm sàng, xét nghiệm cận lâm sàng và hình ảnh học như X-quang, CT scan. Tuy nhiên, việc đưa ra kết luận chẩn đoán vẫn chịu ảnh hưởng bởi:

- Sự khác biệt trong đánh giá của bác sĩ: Các bác sĩ có thể có quan điểm khác nhau khi diễn giải triệu chứng hoặc hình ảnh y khoa.
- Dữ liệu không đầy đủ hoặc không chính xác: Một số bệnh nhân có triệu chứng không điển hình hoặc các xét nghiệm chưa đủ rõ ràng.
- Mất cân bằng dữ liệu: Trong thực tế, số ca viêm phổi thường ít hơn so với các bệnh lý đường hô hấp khác, gây khó khăn trong huấn luyện mô hình chẩn đoán.



Hình 1.1. Biểu đồ số ca nhiễm Covid19 tại Việt Nam giai đoạn tháng 4-5/2023 [21]

Xem xét Hình 1.1, tổng số ca nhiễm COVID-19 trong giai đoạn từ ngày 15/4/2023 đến 07/5/2023 là 6.363 ca nhập cảnh và 11.569.520 ca trong nước. Như vậy, tổng cộng có 11.575.883 ca được ghi nhận trong khoảng thời gian này.

COVID-19 là một minh chứng rõ ràng về sự cần thiết của các hệ thống hỗ trợ chẩn đoán chính xác và nhanh chóng. Virus SARS-CoV-2 gây tổn thương phổi nghiêm trọng, dẫn đến hội chứng viêm phổi nặng (viêm phổi do virus). Tuy nhiên, trong giai đoạn đầu, việc phân biệt viêm phổi do COVID-19 với các nguyên nhân khác gặp nhiều khó khăn do:

- Dữ liệu huấn luyện hạn chế và không đồng nhất: Trong giai đoạn đầu của đại dịch, dữ liệu về bệnh nhân COVID-19 còn ít, chưa đầy đủ và có sự khác biệt giữa các khu vực, làm giảm khả năng tổng quát hóa của các mô hình.
- Triệu chứng lâm sàng chồng lấn: Viêm phổi do COVID-19 có biểu hiện tương tự nhiều loại viêm phổi khác (như viêm phổi do vi khuẩn, nấm hoặc các virus khác), khiến mô hình khó phân biệt dựa trên triệu chứng hoặc hình ảnh y khoa.
- Mất cân bằng dữ liệu: Số ca viêm phổi do COVID-19 thường ít hơn so với các loại viêm phổi khác trong dữ liệu ban đầu, dẫn đến mất cân bằng nhãn, khiến mô hình dễ thiên lệch và giảm hiệu suất nhận diện COVID-19.

1.2. Tiếp cận Bayesian để cải thiện chẩn đoán viêm phổi

Trước những thách thức trên, mạng Bayesian có thể hỗ trợ quá trình suy diễn chẩn đoán bằng cách tích hợp dữ liệu từ nhiều nguồn khác nhau (triệu chứng, xét nghiệm, văn bản y khoa) để tính toán xác suất mắc bệnh, ngay cả khi dữ liệu không đầy đủ.

Hệ thống suy diễn dựa trên mạng Bayes (Bayesian Network - BN) có thể hỗ trợ bác sĩ chẩn đoán viêm phổi một cách chính xác hơn bằng cách:

1. Mô hình hóa mối quan hệ nhân quả giữa các triệu chứng, xét nghiệm và chẩn đoán viêm phổi dựa trên xác suất có điều kiện.
2. Xử lý dữ liệu không đầy đủ bằng cách suy diễn xác suất của chẩn đoán ngay cả khi một số thông tin đầu vào bị thiếu.
3. Cập nhật niềm tin (belief update) khi có thêm thông tin mới, giúp điều chỉnh chẩn đoán theo tiến trình khám bệnh.

4. Đề xuất các xét nghiệm quan trọng nhất, giúp tối ưu hóa quy trình chẩn đoán, tiết kiệm chi phí và thời gian cho bệnh nhân.

Với sự phát triển của trí tuệ nhân tạo trong y tế, mạng Bayesian không chỉ đóng vai trò là một công cụ hỗ trợ ra quyết định mà còn có thể tích hợp với các phương pháp học máy khác để cải thiện độ chính xác và độ tin cậy trong chẩn đoán viêm phổi.

1.3. Tại sao áp dụng văn bản y khoa vào chẩn đoán viêm phổi là cần thiết ?

Văn bản y khoa là các tài liệu chứa thông tin liên quan đến sức khỏe, bao gồm hồ sơ bệnh án, ghi chú lâm sàng, kết quả xét nghiệm, mô tả triệu chứng của bệnh nhân. Những văn bản này do bác sĩ, chuyên gia y tế hoặc các hệ thống y tế ghi chép, giúp lưu trữ và truyền tải thông tin quan trọng trong quá trình chẩn đoán và điều trị.

Việc sử dụng văn bản y khoa trong chẩn đoán viêm phổi là cần thiết vì nó cung cấp thông tin chi tiết về triệu chứng, tiền sử bệnh và các dấu hiệu lâm sàng mà các phương pháp chẩn đoán hình ảnh hoặc xét nghiệm không thể hiện đầy đủ. Các bác sĩ thường ghi chép mô tả chi tiết về tình trạng bệnh nhân, bao gồm triệu chứng như ho, sốt, khó thở, cũng như các yếu tố nguy cơ như bệnh nền hoặc tiền sử nhiễm trùng.

Khi kết hợp các phương pháp xử lý ngôn ngữ tự nhiên (NLP) với mô hình học máy, có thể trích xuất và chuẩn hóa thông tin từ văn bản để hỗ trợ quá trình chẩn đoán. Điều này đặc biệt hữu ích khi dữ liệu hình ảnh hoặc xét nghiệm không có sẵn hoặc chưa đủ rõ ràng, giúp cải thiện độ chính xác và tốc độ phát hiện viêm phổi.

1.4. Hạn chế của mô hình Bayesian

Mặc dù mạng Bayesian mang lại nhiều lợi ích trong việc xử lý dữ liệu không chắc chắn và suy diễn nhân từ dữ liệu lâm sàng, nhưng khi áp dụng vào bài toán chẩn đoán viêm phổi từ văn bản mô tả triệu chứng, mô hình này vẫn gặp phải một số thách thức lớn:

- Thứ nhất, xử lý văn bản y khoa phức tạp do các mô tả triệu chứng không chuẩn hóa, có thể khác nhau giữa các bác sĩ hoặc bệnh viện. Các biểu đạt mang tính chủ quan, viết tắt, và lỗi chính tả khiến mô hình khó học được quy luật thống nhất.
- Thứ hai, sự mơ hồ trong ngữ nghĩa làm giảm hiệu quả của mạng Bayesian. Ví dụ, cụm từ “khó thở nhẹ” có thể xuất hiện ở cả bệnh nhân COVID-19 và bệnh

nhân viêm phổi do nguyên nhân khác, nhưng cường độ và bối cảnh có thể khác nhau. Mạng Bayesian truyền thống dựa vào phân phối xác suất có thể không đủ linh hoạt để phân biệt rõ ràng trong những trường hợp này.


- Thứ ba, hạn chế trong việc khai thác thông tin ngữ cảnh dài. Các triệu chứng thường xuất hiện trong mô tả dài với nhiều chi tiết liên quan. Tuy nhiên, mạng Bayesian có xu hướng xử lý dữ liệu dưới dạng các đặc trưng độc lập hoặc chỉ dựa vào một số ít từ khóa quan trọng, điều này có thể làm mất đi các mối liên hệ quan trọng giữa các triệu chứng.

Do đó, để cải thiện hiệu quả chẩn đoán viêm phổi từ văn bản y khoa, cần kết hợp mạng Bayesian với các phương pháp xử lý ngôn ngữ tự nhiên hiện đại như embedding chuyên biệt (ví dụ: BioLord2023) và mô hình học sâu như mạng Nơ-ron.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Giới thiệu chung về mô hình mạng Bayesian

Mạng Bayesian (Bayesian Network – BN) là một mô hình đồ họa xác suất được sử dụng để biểu diễn mối quan hệ giữa các biến trong một hệ thống không chắc chắn. Trong đó, mỗi nút trong mạng thể hiện một biến ngẫu nhiên, còn các cạnh có hướng giữa các nút thể hiện mối quan hệ xác suất có điều kiện giữa các biến [1]. Mô hình này xuất phát từ lĩnh vực trí tuệ nhân tạo và đã được ứng dụng rộng rãi trong nhiều bài toán khác nhau, chẳng hạn như phân tích dữ liệu văn bản [2], hỗ trợ chẩn đoán y khoa [3], đánh giá bằng chứng khoa học [4], cũng như trong các lĩnh vực quản lý tài nguyên và môi trường [5–8].



Hình 2.1. Cấu trúc Bayesian Network

Theo Pearl, mạng Bayes là một mô hình đồ họa biểu diễn mối quan hệ nhân quả giữa các biến, giúp hỗ trợ quá trình ra quyết định [9]. Các mối quan hệ này có thể được xác định từ dữ liệu thực tế bằng cách áp dụng định lý Bayes hoặc dựa trên kiến thức chuyên gia. Về mặt cấu trúc, mạng Bayes được thể hiện dưới dạng đồ thị có hướng không chu trình DAG, trong đó mỗi nút biểu diễn một biến, còn các cạnh có hướng mô tả mối quan hệ phụ thuộc giữa chúng.

Các biến trong mạng Bayes có thể là biến độc lập hoặc phụ thuộc lẫn nhau. Nếu một nút không có bất kỳ nút cha nào (không có cạnh đi vào), giá trị của nó được xác định bởi một phân phối xác suất riêng biệt. Ngược lại, nếu một nút phụ thuộc vào một hoặc nhiều nút cha, thì giá trị của nó được xác định thông qua phân phối xác suất có điều kiện dựa trên các giá trị của nút cha.

Việc xây dựng một mạng Bayes bao gồm hai giai đoạn chính:

- Học cấu trúc (Structure Learning): Xác định cấu trúc DAG mô tả tốt nhất mối quan hệ giữa các biến trong hệ thống.
- Học tham số (Parameter Learning): Xác định các phân phối xác suất có điều kiện dựa trên dữ liệu thực nghiệm. Bao gồm việc tìm hiểu về các phân phối xác suất có điều kiện dựa vào dữ liệu của từng biến. Định lý Bayes mô tả phân phối xác suất có điều kiện như sau:

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

Mạng Bayes sử dụng xác suất để thể hiện mức độ không chắc chắn trong hệ thống. Khi có thêm thông tin mới, mô hình sẽ cập nhật xác suất, giúp thu hẹp khoảng không chắc chắn và nâng cao độ chính xác trong suy luận. Điều này đặc biệt hữu ích trong các hệ thống hỗ trợ chẩn đoán y khoa, như chẩn đoán viêm phổi, nơi mà dữ liệu đầu vào thường không đầy đủ hoặc có độ biến động cao.

2.2. Ví dụ minh họa về cách hoạt động Bayesian Network

Bayesian Network trong bài toán chẩn đoán viêm phổi dựa trên triệu chứng sẽ được thực hiện trên thuật toán như sau:

❖ GIẢI THUẬT 1: Bayesian-Pneumonia(T)

Đầu vào: Patient dataset T , Bayesian Network structure G , Symptoms S

Đầu ra: Probability $P(Pneumonia|S)$, $P(Infection|S)$ cho mỗi bệnh nhân

1: if CPT is not available then

2: $CPT \leftarrow learnCPT(T)$ // Học từ dataset sử dụng MLE hoặc Bayesian Estimation

3: $BN \leftarrow initialize(G, CPT)$

4: $Infer(BN, S)$

5: for each patient $i \in T$ do

```

6:  $P_i \leftarrow \text{computeProbability}(BN, S_i)$ 
7:   if  $P_i > \theta$  then
8:     Assign label "Pneumonia" to patient  $i$ 
9:   else
10:    Assign label "No Pneumonia"
11:  end for
12: return Predicted labels

```


Theo giải thuật 1 trên, thuật toán Bayesian-Pneumonia(T) được thiết kế nhằm dự đoán xác suất mắc viêm phổi (Pneumonia) và nhiễm trùng (Infection) dựa trên các triệu chứng quan sát được (S) bằng cách sử dụng mạng Bayesian (BN).

Quá trình này bao gồm việc học và suy luận trên một mô hình xác suất đồ thị, cho phép biểu diễn và xử lý sự không chắc chắn trong dữ liệu y khoa. Trước tiên, thuật toán kiểm tra sự tồn tại của bảng xác suất có điều kiện (CPT - Conditional Probability Table). Nếu CPT chưa có sẵn, mô hình sẽ học từ dữ liệu bệnh nhân (T) thông qua phương pháp ước lượng hợp lý cực đại (MLE - Maximum Likelihood Estimation) hoặc ước lượng Bayesian. Sau khi xác định được CPT, mạng Bayesian được khởi tạo với cấu trúc đồ thị (G) và bảng xác suất học được, tạo nền tảng cho quá trình suy luận.

Để chẩn đoán từng bệnh nhân, thuật toán duyệt qua toàn bộ tập dữ liệu, tính toán xác suất $P(\text{Pneumonia} | S)$ dựa trên thông tin triệu chứng quan sát được, sau đó so sánh giá trị này với một ngưỡng xác định trước (θ). Nếu xác suất cao hơn ngưỡng, bệnh nhân được gán nhãn "Pneumonia", ngược lại, mô hình kết luận "No Pneumonia". Cuối cùng, thuật toán trả về tập hợp nhãn dự đoán cho toàn bộ bệnh nhân.

Việc sử dụng mạng Bayesian trong chẩn đoán giúp tận dụng các mối quan hệ phụ thuộc giữa các biến lâm sàng, cho phép mô hình thích nghi với dữ liệu thực tế và cải thiện độ chính xác của dự đoán. Đồng thời, việc điều chỉnh ngưỡng θ có thể giúp tối ưu hóa sự cân bằng giữa độ nhạy (Recall) và độ chính xác (Precision), đảm bảo mô hình có khả năng phát hiện bệnh nhân mắc viêm phổi một cách hiệu quả mà không làm gia tăng quá mức các trường hợp dương tính giả.

Giả sử, ta có tập dữ liệu huấn luyện gồm có 8 dòng dữ liệu và 5 thuộc tính(cột) trong đó thuộc tính cuối (class) là thuộc tính nhãn và cấu trúc như hình dưới 2.2, bảng 2.3 và 2 dòng dữ liệu cho tập test như bảng 2.4.



Hình 2.2: Cấu trúc Bayesian Network mẫu

Bảng 2.3. Tập train

ID	Season (B)	Dyspnea (S0)	Cough (S1)	Nassal (S2)	Pneu (D0)	Inf (D1)
1	Warm	No	Yes	No	No	Yes
2	Cold	Yes	Yes	Yes	Yes	Yes
3	Warm	Yes	No	Yes	No	No
4	Cold	Yes	No	No	No	No
5	Warm	Yes	Yes	No	Yes	No
6	Cold	No	Yes	Yes	No	Yes
7	Warm	No	Yes	Yes	No	Yes
8	Cold	Yes	Yes	No	Yes	No

Bảng 2.4. Tập Test

ID	Season (B)	Dyspnea (S0)	Cough (S1)	Nassal (S2)	Pneu (D0)	Inf (D1)
9	Warm	Yes	No	Yes	?	?
10	Cold	No	Yes	No	?	?

Như đã nói trên thuật toán Bayesian sẽ có 2 phần là học dữ liệu và dự đoán, dựa trên đoạn mã giả thuật toán 1, ta sẽ có các bước thực hiện như sau:

▪ **Bước 1: Tính xác suất có điều kiện (CPT)**

○ **Prior Probabilities (Xác suất tiên nghiệm):**

$$- P(D0 = \text{Yes}) = \frac{\text{Số mẫu có } D0 = \text{Yes}}{\text{Tổng số mẫu}} = \frac{3}{8} = 0.375$$

$$- P(D1 = \text{Yes}) = \frac{\text{Số mẫu có } D1 = \text{Yes}}{\text{Tổng số mẫu}} = \frac{4}{8} = 0.5$$

$$- P(B = \text{Warm}) = \frac{4}{8} = 0.5$$

$$- P(B = \text{Cold}) = \frac{4}{8} = 0.5$$

○ **Conditional Probabilities (Xác suất có điều kiện):**

$$- P(S0 = \text{Yes} \mid B = \text{Warm}) = \frac{\text{Số mẫu có } S0 = \text{Yes}, B = \text{Warm}}{\text{số mẫu có } B = \text{Warm}} = \frac{1}{4} = 0.25$$

$$- P(S0 = \text{Yes} \mid B = \text{Cold}) = \frac{2}{4} = 0.5$$

$$- P(S1 = \text{Yes} \mid B = \text{Warm}) = \frac{3}{4} = 0.75$$

$$- P(S1 = \text{Yes} \mid B = \text{Cold}) = \frac{3}{4} = 0.75$$

$$- P(S2 = \text{Yes} \mid B = \text{Warm}) = \frac{2}{4} = 0.5$$

$$- P(S2 = \text{Yes} \mid B = \text{Cold}) = \frac{2}{4} = 0.5$$

○ **Xác suất triệu chứng theo chẩn đoán:**

$$- P(S0 = \text{Yes} \mid D0 = \text{Yes}) = \frac{\text{Số mẫu có } S0 = \text{Yes}, D0 = \text{Yes}}{\text{số mẫu có } D0 = \text{Yes}} = \frac{2}{3} = 0.67$$

$$- P(S1 = \text{Yes} \mid D0 = \text{Yes}) = \frac{2}{3} = 0.67$$

$$- P(S2 = \text{Yes} \mid D1 = \text{Cold}) = \frac{2}{4} = 0.5$$

▪ **Bước 2: Dự đoán**

○ **Công thức Bayes tổng quát:**

$$- P(D0 = \text{Yes} \mid S0, S1) = \frac{P(S0, S1 \mid D0 = \text{Yes}) P(D0 = \text{Yes})}{P(S0, S1)}$$

$$- P(D1 = \text{Yes} \mid S1, S2) = \frac{P(S1, S2 \mid D1 = \text{Yes}) P(D1 = \text{Yes})}{P(S1, S2)}$$

▪ **Tính cho mẫu ID = 9 (B = Warm, S0 = Yes, S1 = No, S2 = Yes)**

- **Dữ liệu từ CPT:**

$$P(S0 = \text{Yes} | D0 = \text{Yes}) = 0.67$$

$$\begin{aligned} P(S1 = \text{No} | D0 = \text{Yes}) &= 1 - P(S1 = \text{Yes} | D0 = \text{Yes}) \\ &= 1 - 0.67 = 0.33 \end{aligned}$$

$$P(D0 = \text{Yes}) = 0.375$$

- **Theo công thức Bayes tổng quát:**

$$\begin{aligned} P(S0 = \text{Yes}, S1 = \text{No}) &= P(S0 = \text{Yes}, S1 = \text{No} | D0 = \text{Yes}) P(D0 = \text{Yes}) \\ &\quad + P(S0 = \text{Yes}, S1 = \text{No} | D0 = \text{No}) P(D0 = \text{No}) \end{aligned}$$

$$P(S0 = \text{Yes}, S1 = \text{No} | D0 = \text{No}) = P(S0 = \text{Yes} | D0 = \text{No}) P(S1 = \text{No} | D0 = \text{No})$$

$$P(S0 = \text{Yes} | D0 = \text{No}) = 1 - 0.67 = 0.33$$

$$P(S1 = \text{No} | D0 = \text{No}) = 1 - 0.67 = 0.33$$

$$P(D0 = \text{No}) = 1 - 0.375 = 0.625$$

$$\begin{aligned} P(S0 = \text{Yes}, S1 = \text{No}) &= (0.67 \times 0.33 \times 0.375) + (0.33 \times 0.33 \times 0.625) \\ &= (0.0828) + (0.0680) \\ &= 0.1508 \end{aligned}$$

$$\begin{aligned} \Rightarrow P(D0 = \text{Yes} | S0 = \text{Yes}, S1 = \text{No}) &= \frac{0.67 \times 0.33 \times 0.375}{0.1508} \\ &= \frac{0.0829}{0.1508} \\ &= 0.55 \end{aligned}$$

$$\begin{aligned} P(S1 = \text{No}, S2 = \text{Yes}) &= P(S1 = \text{No}, S2 = \text{Yes} | D1 = \text{Yes}) P(D1 = \text{Yes}) \\ &\quad + P(S1 = \text{No}, S2 = \text{Yes} | D1 = \text{No}) P(D1 = \text{No}) \\ &= (0.33 \times 0.5 \times 0.5) + (0.67 \times 0.5 \times 0.5) \\ &= 0.0825 + 0.1675 \\ &= 0.25 \end{aligned}$$

$$\begin{aligned} \Rightarrow P(D1 = \text{Yes} | S1 = \text{No}, S2 = \text{Yes}) &= \frac{0.33 \times 0.5 \times 0.5}{0.25} \\ &= \frac{0.0825}{0.25} \\ &= 0.33 \end{aligned}$$

▪ **Tính cho mẫu ID = 10 (B = Cold, S0 = No, S1 = Yes, S2 = No)**

$$P(S0 = \text{No} | D0 = \text{Yes}) = 1 - 0.67 = 0.33$$

$$P(S1 = \text{Yes} | D0 = \text{Yes}) = 0.67$$

$$P(D0 = \text{Yes}) = 0.375$$

$$\begin{aligned} P(S0 = \text{No}, S1 = \text{Yes}) &= (0.33 \times 0.67 \times 0.375) + (0.67 \times 0.67 \times 0.625) \\ &= (0.0825) + (0.278) \\ &= 0.3605 \end{aligned}$$

$$\begin{aligned} \Rightarrow P(D0 = \text{Yes} | S0 = \text{No}, S1 = \text{Yes}) &= \frac{0.33 \times 0.67 \times 0.375}{0.3605} \\ &= \frac{0.0829}{0.3605} \\ &= \mathbf{0.23} \end{aligned}$$

$$P(S1 = \text{Yes} | D1 = \text{Yes}) = 0.67$$

$$P(S2 = \text{No} | D1 = \text{Yes}) = 1 - 0.5 = 0.5$$

$$P(D1 = \text{Yes}) = 0.5$$

$$\begin{aligned} P(S1 = \text{Yes}, S2 = \text{No}) &= (0.67 \times 0.5 \times 0.5) + (0.33 \times 0.5 \times 0.5) \\ &= (0.1675) + (0.0825) \\ &= 0.25 \end{aligned}$$

$$\begin{aligned} \Rightarrow P(D1 = \text{Yes} | S1 = \text{Yes}, S2 = \text{No}) &= \frac{0.67 \times 0.5 \times 0.5}{0.25} \\ &= \frac{0.1675}{0.25} \\ &= \mathbf{0.67} \end{aligned}$$

▪ **Bước 3: Kết luận**

Bảng 2.5. Bảng kết luận dự đoán ID 9 và ID 10

ID	$P(D0 = \text{Yes} S0, S1)$	$P(D1 = \text{Yes} S1, S2)$	Pneu	Inf
9	0.55	0.33	Yes	No
10	0.23	0.67	No	Yes


⇒ Mẫu 9 (B = Warm, S0 = Yes, S1 = No, S2 = Yes): Chẩn đoán viêm phổi

⇒ Mẫu 10 (B = Cold, S0 = No, S1 = Yes, S2 = No): Chẩn đoán nhiễm trùng

2.3. Mạng Feed-Forward Neural Networks (FFNN)

2.3.1. Cơ sở lý thuyết

Feed-Forward Neural Networks (FFNN) là một dạng của mạng nơ-ron nhân tạo với kiến trúc đơn giản, trong đó thông tin chỉ truyền theo một hướng từ đầu vào đến đầu ra mà không có vòng lặp hay kết nối ngược.[22-23] Một FFNN cơ bản bao gồm:



Hình 2.6: Một mẫu Feed-forward Neural Network với 1 lớp hidden (với 3 neurons)

- **Lớp đầu vào (Input layer):** Nhận dữ liệu ban đầu.
- **Các lớp ẩn (Hidden layers):** Biến đổi dữ liệu qua các phép biến đổi phi tuyến.
- **Lớp đầu ra (Output layer):** Trả về kết quả dự đoán.

Mỗi lớp ẩn trong FFNN áp dụng phép biến đổi tuyến tính ($W \cdot x + b$), sau đó sử dụng hàm kích hoạt như ReLU, Sigmoid hoặc Softmax để đưa ra dự đoán. Quá trình huấn luyện được tối ưu thông qua lan truyền ngược (Backpropagation) và thuật toán tối ưu như Adam hoặc SGD.[24]

Trong mạng nơ-ron nhân tạo, hàm kích hoạt đóng vai trò quan trọng trong việc giới thiệu tính phi tuyến vào mô hình, từ đó giúp mạng có khả năng học và mô phỏng các mối quan hệ phức tạp giữa đầu vào và đầu ra.

Hàm ReLU được định nghĩa bởi công thức $f(x) = \max(0, x)$ trong đó đầu ra bằng 0 nếu đầu vào nhỏ hơn hoặc bằng 0, và bằng chính giá trị đầu vào nếu nó lớn hơn 0. Hàm này có ưu điểm nổi bật là đơn giản trong tính toán và giảm thiểu hiện tượng mất gradient trong quá trình lan truyền ngược, từ đó giúp tăng tốc độ huấn luyện và cải thiện hiệu quả tối ưu trong các lớp ẩn của mạng.

Ngược lại, hàm sigmoid được sử dụng chủ yếu trong lớp đầu ra của các bài toán phân loại nhị phân. Hàm này có dạng toán học là $f(x) = \frac{1}{1 + e^{-x}}$, với đầu ra nằm trong khoảng (0, 1), phù hợp để biểu diễn xác suất của một biến nhị phân. Tuy nhiên, điểm hạn chế của sigmoid là dễ gây ra hiện tượng "vanishing gradient" trong các mạng sâu, ảnh hưởng đến hiệu quả huấn luyện.

Việc lựa chọn hàm kích hoạt phù hợp cho từng lớp trong mạng là một yếu tố then chốt quyết định hiệu suất của mô hình. Trong thực tiễn, ReLU thường được áp dụng ở các lớp ẩn để khai thác tính phi tuyến, trong khi sigmoid được ưu tiên sử dụng ở lớp đầu ra nhằm phục vụ mục đích phân loại xác suất.

2.3.2. Mô hình Mạng Nơ-ron Lan Truyền Tiến Tuyến Tính (Feedforward Neural Network - FFNN) theo Kiến trúc Tuần Tự (Sequential)

Trong nghiên cứu này, mô hình Mạng Nơ-ron Lan Truyền Tiến (Feedforward Neural Network - FFNN) được triển khai theo kiến trúc tuần tự (Sequential) để thực hiện nhiệm vụ trích xuất thông tin triệu chứng từ văn bản lâm sàng đã được ánh xạ sang không gian vector thông qua kỹ thuật embedding chuyên biệt.

Trong bối cảnh bài toán đặt ra, văn bản đầu vào (thường là ghi chú y tế, báo cáo bệnh án hoặc câu hỏi khai thác triệu chứng) được mã hóa thành các vector đặc

trung cố định chiều bằng các mô hình embedding ngữ nghĩa chuyên biệt trong y học, chẳng hạn như BioBERT, BioClinicalBERT, hoặc BioLoRD. Các embedding này cho phép trừu tượng hóa thông tin ngôn ngữ và ngữ cảnh từ văn bản sang các biểu diễn số, phục vụ cho việc học đặc trưng hiệu quả.

Khi đầu vào đã được biểu diễn dưới dạng vector, mô hình FFNN trở thành lựa chọn hợp lý và hiệu quả cho nhiệm vụ trích xuất triệu chứng theo hướng phân loại. Mỗi vector embedding sẽ được đưa vào mạng FFNN như một điểm dữ liệu, và mô hình sẽ học ánh xạ từ không gian biểu diễn này sang các nhãn triệu chứng (symptom labels) tương ứng, ví dụ như dysp (yes/no), cough (yes/no), hoặc fever (none/low/high).

Việc sử dụng kiến trúc tuần tự (Sequential) mang lại một số ưu điểm quan trọng:

1. Tương thích với embedding vector: Mô hình FFNN không yêu cầu thông tin theo thứ tự chuỗi như RNN hoặc Transformer, do đó phù hợp với các biểu diễn tĩnh được tạo ra từ các bước embedding trước đó.
2. Cấu trúc đơn giản, dễ huấn luyện: FFNN theo kiến trúc tuần tự dễ dàng xây dựng với một chuỗi các tầng tuyến tính, phù hợp cho các bài toán phân loại đa nhãn hoặc nhiều lớp trong không gian nhãn triệu chứng.
3. Khả năng học phi tuyến: Các tầng phi tuyến (ví dụ: ReLU, tanh) cho phép mô hình học các mối quan hệ phức tạp giữa biểu diễn ngữ nghĩa của văn bản và các thuộc tính lâm sàng đầu ra.
4. Khả năng mở rộng tốt: Mô hình có thể dễ dàng mở rộng để dự đoán nhiều triệu chứng đồng thời, sử dụng các hàm kích hoạt và hàm mất mát phù hợp (ví dụ: sigmoid và binary cross-entropy cho các nhãn nhị phân độc lập).

Tóm lại, mô hình FFNN theo kiến trúc tuần tự (Sequential) là một phương pháp phù hợp, đơn giản nhưng hiệu quả để học ánh xạ từ biểu diễn embedding của văn bản y khoa sang các đặc trưng triệu chứng cần suy luận, đặc biệt trong các hệ thống hỗ trợ chẩn đoán hoặc phân tích ngữ nghĩa trong hồ sơ bệnh án điện tử.

2.4. Phương pháp giải thích mô hình máy học (XAI) LIME và SHAP

2.4.1. Giới thiệu

Theo Molnar [14] và Guidotti [10], XAI cung cấp một tập hợp các kỹ thuật, quy trình và công cụ cho phép các mô hình học máy trở nên minh bạch hơn. Điều này không chỉ hỗ trợ việc ra quyết định của con người mà còn nâng cao niềm tin và khả năng giải trình của hệ thống AI.

Hai kỹ thuật giải thích mô hình phổ biến nhất hiện nay là LIME (Local Interpretable Model-agnostic Explanations) và SHAP (SHapley Additive exPlanations) [9-13]. Cả hai phương pháp đều nhằm cung cấp cái nhìn sâu sắc vào cơ chế hoạt động của mô hình, song mỗi phương pháp lại tiếp cận vấn đề theo cách khác nhau.

2.4.2. LIME

LIME tập trung vào giải thích cục bộ, tức là tại thời điểm đánh giá một cá thể cụ thể (ví dụ: một bệnh nhân cụ thể), LIME xây dựng một mô hình tuyến tính đơn giản xung quanh điểm dữ liệu đó để xác định các đặc trưng có ảnh hưởng nhất đến quyết định của mô hình tại điểm đó. Phương pháp này đặc biệt hữu ích khi mô hình chính là một mạng Bayesian phức tạp và khó trực tiếp diễn giải.

Công thức LIME: $explanation(x) = argmin_{\{g \in G\}} L(f, g, \pi_x) + \Omega(g)$

- x : điểm dữ liệu được xét
- f : original model
- g : explanation model (linear, tree,...)
- π : proximity measure từ x (có thể là $L2$ norm, cosine ...)
- π_x : điểm dữ liệu được biến đổi
- $\Omega(g)$: độ phức tạp thuật toán. Eg: $\sqrt{(len(feature)) \times 0.75}$

2.4.3. SHAP

SHAP sử dụng lý thuyết trò chơi Shapley để lượng hóa mức độ đóng góp của từng đặc trưng đầu vào đối với quyết định đầu ra của mô hình.

Giá trị Shapley (Shapley value) là một khái niệm nền tảng trong lý thuyết trò chơi hợp tác, được sử dụng để phân phối phần thưởng giữa các cá nhân dựa trên mức độ đóng góp của họ. Giá trị này được xác định duy nhất bởi bốn tiên đề (axioms) cơ bản:

5. **Efficiency** - Hiệu suất: tổng phần thưởng phân phối phải bằng tổng giá trị tạo ra bởi cả nhóm.
6. **Symmetry** - Tính đối xứng: những người chơi có đóng góp ngang nhau sẽ nhận được phần thưởng bằng nhau.
7. **Dummy Player** - Người chơi vô dụng: nếu một người không tạo ra giá trị gia tăng nào, họ sẽ không được nhận phần thưởng.
8. **Additivity** - Tính cộng gộp: trong trường hợp nhóm tham gia nhiều trò chơi, phần thưởng của từng cá nhân trong trò chơi tổng hợp sẽ bằng tổng phần thưởng họ nhận được từ từng trò chơi riêng lẻ.

Trong Explainable AI như SHAP, các axioms này được dùng để phân phối ảnh hưởng của từng feature đến đầu ra mô hình một cách công bằng. Phương pháp này cung cấp cái nhìn toàn cục về vai trò của từng đặc trưng trong toàn bộ mô hình, giúp các nhà nghiên cứu hiểu được đâu là yếu tố ảnh hưởng lớn nhất đến khả năng chẩn đoán bệnh.[15]

Công thức Shapley Value:

$$\phi_i(p) = \sum_{S \subseteq \{N/i\}} \frac{|S|!(n-|S|-1)!}{n!} (p(S \cup i) - p(S))$$


- p : Giá trị dự đoán (prediction) của mô hình ban đầu cho mẫu x
- $\phi_i(p)$: Giá trị thể hiện mức độ ảnh hưởng của đặc trưng (feature) i đối với dự đoán p .
- S : Một tập con các feature không chứa i xét theo mọi hoán vị thứ

tự của các feature (permutation).

- n : Tổng số feature.
- $p(S)$: Giá trị dự đoán của mô hình khi chỉ sử dụng các feature trong tập S .

2.4.4. Quy trình thực hiện và ý nghĩa đóng góp

Để dễ hình dung, nghiên cứu thực hiện theo các thứ tự công việc như sau:



Hình 2.7. Quy trình giải thích mô hình máy học sử dụng LIME và SHAP

Hình 2.7 minh họa quy trình tổng quát trong việc giải thích mô hình học máy, bao gồm cả mô hình hộp đen (black-box) và mô hình hộp trắng (white-box).

Sau bước tiền xử lý dữ liệu, dữ liệu được đưa vào hai nhóm mô hình: nhóm hộp đen gồm các thuật toán như SVM, Random Forest, Neural Network và XGBoost – những mô hình thường có cấu trúc phức tạp, khó hiểu và không cung cấp thông tin trực tiếp về cách ra quyết định. Để giải thích đầu ra của các mô hình này, các phương pháp giải thích mô hình như LIME và SHAP được sử dụng để sinh ra các giải thích mà con người có thể hiểu được.

Ngược lại, nhóm mô hình hộp trắng – điển hình là các mô hình dựa trên lý thuyết xác suất như Bayesian Networks – vốn có cấu trúc rõ ràng, dễ giải thích và thường không cần đến các phương pháp như LIME hay SHAP. Tuy nhiên, việc áp dụng LIME/SHAP lên cả mô hình white-box nhằm hai mục đích: (1) chuẩn hóa cách giải thích giữa các mô hình trong cùng một hệ thống để so sánh trực quan hơn, và (2) củng cố thêm góc nhìn định lượng về mức độ ảnh hưởng của từng đặc trưng đầu vào, ngay cả khi mô hình vốn đã dễ hiểu. Điều này đặc biệt hữu ích trong môi trường lâm sàng hoặc y tế, nơi mà việc cung cấp các giải thích rõ ràng, nhất quán và đáng tin

cậy cho các chuyên gia là vô cùng quan trọng.


Trong bối cảnh xây dựng mạng Bayesian để suy luận chẩn đoán viêm phổi, cả LIME và SHAP đều có thể được sử dụng như công cụ chọn lọc đặc trưng (feature selection) một cách có định hướng.

Cụ thể, các đặc trưng có giá trị SHAP cao hoặc trọng số LIME lớn trên tập dữ liệu huấn luyện có thể được coi là những biến quan sát hoặc nút trung gian có ảnh hưởng lớn đến khả năng mắc viêm phổi, và do đó cần được đưa vào mạng Bayesian dưới dạng các node quan trọng và quan hệ giữa chúng.

Việc sử dụng kết quả từ LIME/SHAP không chỉ hỗ trợ hiểu rõ vai trò của từng yếu tố lâm sàng, mà còn giúp định hướng cấu trúc mạng Bayesian một cách hợp lý hơn – chẳng hạn, nếu shortness of breath và chest pain có ảnh hưởng mạnh và đồng thời cùng góp phần tăng xác suất pneumonia, thì mối quan hệ phụ thuộc giữa các node này nên được mô hình hóa rõ ràng trong cấu trúc mạng. Nhờ đó, mô hình suy luận Bayesian trở nên chính xác và sát thực tế lâm sàng hơn, đặc biệt khi kết hợp với dữ liệu có nguồn gốc văn bản hoặc báo cáo triệu chứng.

CHƯƠNG 3: MÔ HÌNH ĐỀ XUẤT

3.1. Mạng Bayesian theo kiến thức chuyên gia



Hình 3.1. Cấu trúc DAG theo kiến thức chuyên gia

Trong nghiên cứu này, nhóm xây dựng mạng Bayes dựa trên kiến thức chuyên gia nhằm hỗ trợ chẩn đoán viêm phổi, với cấu trúc được biểu diễn dưới dạng đồ thị có hướng không chu trình DAG như trên hình 3.4[16].

Biểu thức xác suất phân phối chung (joint distribution) được mô hình bằng mạng Bayesian được biểu diễn như sau:

$$\begin{aligned}
 &P_{\text{joint}}(\text{asthma}, \text{smoking}, \dots, \text{fever}, \text{nassal}) \\
 &= P(\text{asthma})P(\text{smoking})P(\text{COPD}|\text{smoking})P(\text{hay_fever})P(\text{season}) \\
 &\quad P(\text{pneu}|\text{asthma}, \text{COPD}, \text{season})P(\text{inf}|\text{season}) \\
 &\quad P(\text{dysp}|\text{asthma}, \text{smoking}, \text{COPD}, \text{pneu}, \text{hay_fever}) \\
 &\quad P(\text{cough}|\text{asthma}, \text{smoking}, \text{pneu}, \text{inf}) \\
 &\quad P(\text{pain}|\text{cough}, \text{pneu}, \text{COPD}, \text{inf}) \\
 &\quad P(\text{fever}|\text{pneu}, \text{inf})P(\text{nassal}|\text{inf}, \text{hay_fever})
 \end{aligned}$$

Mạng bao gồm các nút đại diện cho các biến lâm sàng có thể quan sát hoặc ẩn, cùng với các cung hướng biểu diễn mối quan hệ nhân quả giữa chúng. Việc xây dựng sơ đồ cấu trúc mạng Bayes này không chỉ dựa trên dữ liệu mà còn được củng cố bởi kiến thức chuyên sâu từ các chuyên gia y tế, nhằm đảm bảo tính hợp lý trong

bối cảnh lâm sàng thực tế.

Bảng 3.2. Mô tả các biến trên cấu trúc DAG

Biến	Tiếng Việt	Phân loại	Mô tả	Giá trị
Season	Mùa trong năm	Yếu tố bên ngoài	Mùa trong năm (mùa đông hoặc hè).	winter /summer
Asthma	Hen suyễn	Clinical	Bệnh hen suyễn, gây hẹp và viêm đường thở.	yes/no
Smoking	Hút thuốc	Clinical	Bệnh nhân có hút thuốc hay không.	yes/no
COPD	Bệnh phổi tắc	Clinical	Bệnh phổi tắc nghẽn mạn tính, gây khó thở do tắc nghẽn phổi.	yes/no
Hay_fever	Viêm mũi dị ứng	Clinical	Dị ứng theo mùa, gây ngứa hoặc sổ mũi do phấn hoa hay dị nguyên.	yes/no
Dyspnea	Khó thở	Symptoms	Khó thở, cảm giác không đủ hơi.	yes/no
Cough	Ho	Symptoms	Ho (bao gồm ho khan hoặc có đờm).	yes/no
Pain	Đau	Symptoms	Đau vùng ngực hoặc đường thở.	yes/no
Fever	Sốt	Symptoms	Sốt, nhiệt độ cơ thể tăng cao.	high /low/none
Nassal	Triệu chứng mũi	Symptoms	Các triệu chứng ở mũi như nghẹt mũi, chảy mũi.	yes/no
Pneumonia	Viêm phổi	Diagnosis	Viêm phổi, gây viêm túi khí ở một hoặc cả hai lá phổi.	yes/no
Infection	Nhiễm trùng	Diagnosis	Nhiễm trùng đường hô hấp trên, gây nghẹt mũi, ho.	yes/no

Mỗi cung trong sơ đồ phản ánh mối quan hệ nhân quả đã được xác nhận bởi kiến thức y học hiện hành. Ví dụ, hút thuốc làm tăng nguy cơ ho và đau ngực, trong khi các bệnh nền như hen suyễn và COPD ảnh hưởng đến khó thở, từ đó gián tiếp liên quan đến khả năng mắc viêm phổi.


Một điểm nổi bật trong mạng là sự phân biệt giữa Pneumonia và Infection như hai biến ẩn riêng biệt, cho phép mô hình đánh giá khả năng mắc viêm phổi một cách chuyên biệt, thay vì gộp chung vào nhóm bệnh nhiễm trùng hô hấp. Ngoài ra, yếu tố thời vụ (Season) cũng được đưa vào để phản ánh đặc điểm dịch tễ theo mùa – đây là một đặc tính thường bị bỏ qua trong các mô hình học máy đơn thuần nhưng lại có ý nghĩa lâm sàng quan trọng.

Việc tích hợp kiến thức chuyên gia giúp cải thiện tính khả diễn giải và độ tin cậy của mô hình, đặc biệt hữu ích trong các tình huống dữ liệu huấn luyện còn hạn chế. Mạng Bayes này không chỉ hỗ trợ tiên đoán khả năng mắc viêm phổi dựa trên các dấu hiệu và yếu tố nguy cơ đầu vào, mà còn cung cấp khả năng suy diễn ngược (inference) để lý giải tại sao một bệnh nhân được chẩn đoán như vậy – một yếu tố then chốt trong các hệ thống hỗ trợ quyết định y khoa hiện đại

3.2. Mạng Bayesian Baseline

Để đánh giá hiệu quả của các mô hình học sâu và mô hình lai (hybrid), nhóm thiết lập một mô hình nền tảng (baseline) dựa trên mạng Bayes – gọi là Bayesian Network Baseline (BN). Mô hình này đóng vai trò là điểm chuẩn để so sánh, đồng thời khai thác khả năng suy diễn xác suất có điều kiện từ các biểu diễn nhân quả theo kiến thức chuyên gia.

Cấu trúc tổng quan của mô hình: Như thể hiện trong Hình 3.3, mô hình BN baseline bao gồm hai khối chính – tương ứng với hai cấu hình đầu vào khác nhau:



Hình 3.3. Sơ đồ mô hình Bayesian Network Baseline

▪ Khối 1: Dựa trên Season và Knowledge

Khối trên cùng trong sơ đồ thể hiện cấu hình đơn giản hóa, nơi mô hình sử dụng hai nguồn thông tin đầu vào:

- Season (Mùa): được mã hóa one-hot, phản ánh mùa trong năm (mùa hè hoặc mùa đông), yếu tố ảnh hưởng đến nguy cơ nhiễm bệnh hô hấp.
- Knowledge (tri thức chuyên gia): đóng vai trò như DAG, tức cấu trúc mạng Bayes được xây dựng từ mối quan hệ nhân quả đã được chuyên gia xác lập.

Trong quá trình xử lý:

- Dữ liệu Season được sử dụng để tạo nên bảng xác suất có điều kiện CPT đối với biến Pneumonia.
- Mạng DAG cùng CPT sẽ được sử dụng để tiến hành Bayesian inference – quá trình suy diễn xác suất xảy ra của Infection.

Cấu hình này đại diện cho mô hình suy luận thuần túy dựa vào tri thức, không sử dụng bất kỳ dữ liệu bệnh nhân cụ thể nào khác ngoài yếu tố mùa vụ.

▪ **Khối 2: Dựa trên Clinical, Symptoms và Knowledge**

Khối thứ hai trong sơ đồ là mô hình nền đầy đủ hơn, nơi sử dụng các nguồn dữ liệu thực tế:


- Season (Mùa)
- Clinical: các đặc trưng tiền sử của bệnh nhân như bệnh nền, hút thuốc...
- Symptoms: các biểu hiện lâm sàng như ho, sốt, đau ngực, khó thở...
- Knowledge: cấu trúc DAG được xây dựng từ kiến thức chuyên gia, đóng vai trò làm nền cho suy diễn xác suất.

Cả Clinical và Symptoms đều được mã hóa dưới dạng one-hot encoding. Các đầu vào này được ánh xạ đến các nút tương ứng trong mạng Bayes. Mỗi biến trong mạng sẽ có bảng CPT riêng, từ đó sử dụng thuật toán suy diễn (Bayesian inference) để tính toán xác suất xảy ra của Pneumonia và Infection.

Trong nghiên cứu này, BN baseline đóng vai trò quan trọng như một chuẩn tham chiếu, nhưng các mô hình nâng cao hơn (mô hình lai neural-Bayes hoặc mạng sâu xử lý văn bản) được phát triển để khắc phục các hạn chế trên và hướng đến hiệu quả chẩn đoán cao hơn trong thực tế.

3.3. Mô hình Embedding văn bản

Khi làm việc với dữ liệu văn bản, một bước quan trọng là biểu diễn văn bản dưới dạng vector số để có thể đưa vào mô hình học sâu. BioLord2023 embedding giúp chuyển đổi văn bản y khoa thành các vector có 768 chiều, chứa thông tin về ngữ nghĩa và ngữ cảnh của mô tả triệu chứng viêm phổi.



Hình 3.4: Quy trình Embedding text với model BioLord2023

Hình 3.4. thể hiện quy trình xử lý văn bản gồm:


- **Tiền xử lý:** Chuẩn hóa văn bản (loại bỏ ký tự đặc biệt, chuyển đổi chữ viết thường, tách từ).
- **Embedding:** Sử dụng mô hình BioLord2023 để chuyển đổi văn bản thành vector 768 chiều.

Mô hình embedding được sử dụng là BioLoRD-2023 – một phiên bản được huấn luyện đặc biệt trên văn bản y sinh và lâm sàng, có khả năng hiểu ngữ nghĩa đặc trưng trong các mô tả bệnh án. Cụ thể, nhóm sử dụng lớp SentenceTransformer từ thư viện sentence_transformers để tải mô hình và mã hóa văn bản từ cột text trong bộ dữ liệu. Mỗi dòng văn bản, tương ứng với một mô tả triệu chứng, được chuyển đổi thành một vector có độ dài cố định (thường là 768 chiều), phản ánh ngữ nghĩa tổng thể của câu.

Tổng thể, bước embedding là cầu nối quan trọng giúp chuyển đổi dữ liệu văn bản không cấu trúc sang dạng có thể xử lý bởi các mô hình học máy, đặc biệt là mạng nơ-ron sâu. Kết quả embedding không chỉ phục vụ cho mục tiêu trích xuất triệu chứng mà còn đóng vai trò trung tâm trong việc suy luận chẩn đoán tự động từ biểu hiện ngôn ngữ của bệnh nhân.

3.4. Mô hình Neural Network

Biểu đồ Hình 3.5 minh họa mô hình sử dụng Feedforward Neural Network (FNN) để dự đoán hai nhãn đầu ra: Pneumonia và Infection. Hệ thống này có ba loại đầu vào: Symptoms, Clinical, và Text, mỗi loại được xử lý theo cách khác nhau trước khi đưa vào mô hình. Cụ thể, dữ liệu dạng Symptoms và Clinical được mã hóa bằng Onehot Encoding, trong khi dữ liệu Text được chuyển đổi thành vector thông qua Word Embedding. Các đầu vào này sau đó được kết hợp và đưa vào mạng FNN để tính toán xác suất mắc bệnh.



Hình 3.5. Mô hình Neural Network

Bảng 3.6 minh họa sáu cấu hình khác nhau được triển khai trong nghiên cứu nhằm đánh giá tác động của từng loại dữ liệu và kỹ thuật biểu diễn lên hiệu quả chẩn đoán viêm phổi trong mô hình Neural Network.

Bảng 3.6. Cấu hình input Neural Network

Cấu hình	Symptoms	Clinical	Text
1	✓		
2		✓	
3	✓	✓	
4			✓
5		✓	✓
6	✓	✓	✓

1. Cấu hình 1: Triệu chứng (Symptoms)

Trong cấu hình đầu tiên, mô hình chỉ sử dụng thông tin về triệu chứng dưới dạng chuỗi văn bản đã được mã hóa bằng phương pháp onehot encoding. Mỗi triệu chứng (ví dụ: ho, sốt, đau ngực, khó thở) được chuyển thành vector nhị phân, trong đó mỗi chiều đại diện cho một triệu chứng cụ thể. Sau đó, vector này được đưa vào mạng nơ-ron truyền thẳng FNN để dự đoán xác suất mắc viêm phổi (Pneumonia) và nhiễm trùng hô hấp (Infection). Đây là mô hình nền đơn giản, dùng để so sánh với các biến thể phức tạp hơn.

2. Cấu hình 2: Dữ liệu lâm sàng (Clinical)

Mô hình thứ hai sử dụng thông tin lâm sàng có cấu trúc như tiền sử bệnh, tình trạng hút thuốc, bệnh nền (ví dụ: hen suyễn, COPD), mã hóa theo dạng onehot tương tự. Việc tách biệt triệu chứng và dữ liệu lâm sàng cho phép đánh giá mức độ đóng góp của từng nhóm biến đối với kết quả chẩn đoán.

3. Cấu hình 3: Kết hợp Clinical và Symptoms

Cấu hình thứ ba là bước kết hợp đầu tiên giữa hai nguồn dữ liệu: thông tin lâm sàng và triệu chứng. Cả hai đầu vào đều được mã hóa onehot, sau đó ghép nối và đưa vào mạng FNN. Đây là một trong những mô hình quan trọng vì cho phép khai thác tính cộng hưởng giữa yếu tố nguy cơ và biểu hiện bệnh lý.

4. Cấu hình 4: Text Symptoms – Word Embedding

Từ cấu hình thứ tư trở đi, mô hình bắt đầu sử dụng word embedding, một phương pháp biểu diễn văn bản tiên tiến hơn so với onehot. Ở đây, văn bản mô tả triệu chứng được ánh xạ thành các vector liên tục trong không gian nhúng, phản ánh ngữ nghĩa của các từ (ví dụ: "sốt cao" và "nhiệt độ tăng" có thể gần nhau trong không gian embedding). Các vector này sau đó được xử lý qua mạng FNN. Việc sử dụng word embedding giúp mô hình học được mối quan hệ ngữ nghĩa giữa các biểu thức triệu chứng, đặc biệt hiệu quả trong các trường hợp văn bản phong phú hoặc biểu đạt không đồng nhất.

5. Cấu hình 5: Kết hợp Text + Clinical

Cấu hình này kết hợp giữa dữ liệu văn bản mô tả triệu chứng (embedding)


và dữ liệu lâm sàng (mã hóa onehot). Sau khi biểu diễn, hai nguồn đầu vào được hợp nhất và đưa qua mạng FNN để đưa ra tiên đoán. Mô hình này phản ánh một bước tiến so với Mô hình 3, vì sử dụng biểu diễn embedding cho văn bản, thay vì onehot rời rạc.

6. Cấu hình 6: Kết hợp Text + Clinical + Symptoms

Cấu hình toàn diện nhất là Mô hình 6, nơi cả ba nguồn dữ liệu – văn bản triệu chứng (Text), dữ liệu lâm sàng (Clinical), và biểu hiện triệu chứng dạng định danh (Symptoms) – đều được tích hợp. Cụ thể, phần văn bản được embedding, trong khi dữ liệu lâm sàng và các triệu chứng được mã hóa onehot. Tất cả được nối lại và đưa vào mạng FNN. Mục tiêu là tận dụng tối đa thông tin có thể từ cả ba loại đầu vào: định tính, định lượng và ngôn ngữ tự nhiên.

3.5. Mạng Neural kết hợp mạng Bayesian

Hình 3.7 mô tả một mô hình lai giữa mạng neural và mạng Bayesian (Text2Clinical Network), được thiết kế nhằm tận dụng đồng thời khả năng biểu diễn ngữ nghĩa sâu từ văn bản (text) và khả năng suy diễn nhân quả từ tri thức chuyên gia. Mô hình này được xem là cầu nối giữa học máy dựa trên dữ liệu và suy luận theo kiến thức nền tảng y học.



Hình 3.7. Sơ đồ mô hình BN + Neural Network (Text2Clinical)

▪ **Cấu trúc tổng thể mô hình bao gồm ba luồng đầu vào chính:**

- Text: Mô tả triệu chứng dưới dạng văn bản không cấu trúc.
- Clinical: các thông tin định danh hoặc đặc điểm nền của bệnh nhân (ví dụ: hút thuốc, COPD, tiền sử hen suyễn).
- Knowledge: kiến thức chuyên gia được biểu diễn dưới dạng mạng Bayes DAG đã được thiết kế từ trước.


▪ **Quy trình xử lý:**

1. Text đầu tiên được ánh xạ thành không gian vector nhờ embedding chuyên biệt là BioLord Embedding.
2. Vector biểu diễn từ BioLord được đưa qua FNN để học các biểu hiện đặc trưng của Symptoms. Đây là bước triệu chứng hóa tự động từ văn bản.
3. Đồng thời, Clinical được mã hóa dưới dạng one-hot và đưa vào CPT – nơi mô hình học được các mối quan hệ xác suất giữa triệu chứng và bệnh (Pneumonia, Infection).
4. Bayes DAG từ Knowledge đóng vai trò dẫn truyền các quan hệ nhân quả trong mô hình Bayesian, từ đó kích hoạt Bayesian Inference để suy diễn kết quả cuối cùng về xác suất viêm phổi và nhiễm trùng.

Việc sử dụng mạng FNN để trích xuất biểu diễn symptoms từ văn bản giúp mô hình xử lý hiệu quả dữ liệu phi cấu trúc, trong khi Bayesian DAG đảm bảo sự minh bạch và giải thích được trong suy luận.

Mặc dù mạng FNN cho kết quả khả quan trong việc suy diễn triệu chứng từ văn bản, nhóm nghiên cứu đặt ra câu hỏi liệu các mô hình học máy cổ điển có thể thay thế hoặc hỗ trợ vai trò này một cách hiệu quả hay không.

Do đó, trong các bước tiếp theo, nhóm sẽ tiến hành so sánh hiệu suất của các mô hình XGBoost, RF, SVM như hình 3.8:



Hình 3.8. Sơ đồ các mô hình so sánh


1. XGBoost: Nổi bật với khả năng khai thác các đặc trưng phi tuyến tính, thích hợp cho bài toán phân loại nhị phân từ đặc trưng văn bản đã embedding.
2. Random Forest: phương pháp tổ hợp cây quyết định, có khả năng xử lý tốt nhiễu và đánh giá mức độ quan trọng của đặc trưng.
3. Support Vector Machine: hiệu quả với không gian biểu diễn có chiều cao như embedding, và cho độ chính xác cao trong phân loại nhị phân.

Các mô hình này sẽ được dùng để trích xuất hoặc phân loại triệu chứng từ văn bản đầu vào, sau đó đưa vào pipeline suy diễn Bayesian như ở hình 3.10. Kết quả từ các mô hình FNN, XGBoost, RF và SVM sẽ được so sánh toàn diện về độ chính xác, khả năng tổng quát và tính giải thích nhằm đánh giá khả năng thay thế hoặc kết hợp với mạng neural trong nhiệm vụ chẩn đoán viêm phổi từ văn bản tự do.

CHƯƠNG 4: THỰC NGHIỆM VÀ BÌNH LUẬN

4.1. Dữ liệu thực nghiệm.

Tập dữ liệu được sử dụng trong nghiên cứu được trích xuất từ bài báo [16]. Dataset SynSUM bao gồm tổng cộng 10.000 mẫu dữ liệu, với 8.000 mẫu dành cho tập huấn luyện và 2.000 mẫu cho tập kiểm tra. Dữ liệu có tổng cộng 13 cột, trong đó có 2 cột nhãn quan trọng là "pneu" và "inf". Cột "pneu" biểu thị chẩn đoán viêm phổi của bệnh nhân, với hai giá trị: "yes" nếu bệnh nhân được chẩn đoán mắc viêm phổi và "no" nếu không mắc. Cột "inf" biểu thị tình trạng nhiễm trùng đường hô hấp, cũng có hai giá trị: "yes" nếu bệnh nhân có dấu hiệu nhiễm trùng và "no" nếu không.



Hình 4.1. Stack Bar Chart SynSum Dataset

Từ hình 4.1, trong nhóm các đặc điểm lâm sàng (clinical), phần lớn bệnh nhân không mắc các bệnh nền như hen suyễn (asthma), bệnh phổi tắc nghẽn mạn tính (COPD) hay viêm mũi dị ứng (hay fever), thể hiện qua tỉ lệ giá trị bằng 0 chiếm ưu thế. Tuy nhiên, đặc điểm hút thuốc (smoking) cho thấy sự phân bố đa dạng hơn

với sự hiện diện đáng kể của cả hai giá trị 0 và 1.

Đối với nhóm triệu chứng (symptoms), các biểu hiện như ho (cough), sốt (fever) và nghẹt mũi (nasal) xuất hiện với tần suất cao, phản ánh mức độ phổ biến của các triệu chứng này trong quần thể bệnh nhân.

Cuối cùng, đặc điểm mùa (season) cho thấy phân bố tương đối cân bằng giữa các giá trị, cho thấy dữ liệu không bị thiên lệch đáng kể theo mùa.

Bảng 4.2: Pneumonia và Infection trong SynSUM Dataset

STT	Chẩn đoán	Số lượng	
		Dương tính	Âm tính
1	Pneumonia	103	9897
2	Infection	2335	7665

Như phân tích trên bảng 4.2, trong dataset SynSUM, tỷ lệ bệnh nhân được chẩn đoán viêm phổi (Pneumonia) là rất thấp, phản ánh thực tế dịch tễ trong khám bệnh thông thường tại Bỉ. Điều này tạo ra một tình huống học máy đầy thử thách: mất cân bằng nhãn nghiêm trọng giữa trường hợp âm tính và dương tính với viêm phổi.

Trong các mô hình phân loại truyền thống (như XGBoost, SVM, RF hoặc mạng nơ-ron), số lượng mẫu dương tính thấp dễ khiến mô hình học sai lệch, bỏ sót nhãn hiếm. Tuy nhiên, trong mô hình Bayes, điều này lại có thể được biến thành một lợi thế.

Khác với các mô hình "học dựa trên tần suất", mô hình Bayes sử dụng kiến thức chuyên môn để định nghĩa xác suất tiên nghiệm (prior) và mối quan hệ nguyên nhân – kết quả (causal).

Ngay cả khi mẫu dương tính với pneumonia hiếm, mô hình Bayes vẫn có thể suy luận được khả năng mắc bệnh nếu thấy tổ hợp triệu chứng phù hợp, nhờ:

- Cấu trúc nhân quả đã được thiết kế từ chuyên gia (ví dụ: $P(\text{dyspnea} | \text{pneumonia})$ cao).
- Mô hình có thể suy luận ngược: nếu bệnh nhân sốt cao + ho + khó thở $\rightarrow$ xác suất bị pneumonia tăng lên đáng kể dù prior thấp.

Tức là, mô hình không cần nhiều mẫu pneumonia để “nhận ra” dấu hiệu đặc trưng của bệnh. Hơn nữa, điều kiện này giúp đánh giá mô hình sâu sắc hơn

Với tỷ lệ dương tính thấp, mô hình Bayes có cơ hội chứng minh khả năng phân biệt tinh tế giữa các bệnh có biểu hiện gần giống nhau (ví dụ: pneumonia và infection). Điều này phản ánh một bài toán chẩn đoán y tế thực tế, nơi bệnh hiếm cần được phát hiện sớm và chính xác dù biểu hiện mơ hồ.

Số lượng mẫu dương tính với pneumonia trong SynSUM thấp không phải là một giới hạn, mà là một kịch bản lý tưởng để đánh giá khả năng suy luận dựa trên kiến thức của mô hình Bayes.

Đây là môi trường mô phỏng thực tế, nơi dữ liệu không đầy đủ nhưng yêu cầu mô hình phải đưa ra quyết định hợp lý – một đặc điểm rất phù hợp cho các hệ thống hỗ trợ ra quyết định trong y học.

Ngoài ra, tập dữ liệu còn bao gồm một cột văn bản chứa mô tả triệu chứng lâm sàng của bệnh nhân, cùng với các cột đặc trưng khác liên quan đến triệu chứng và lâm sàng như hình 4.3.

SAMPLE PATIENT 1	PATIENT 3
The patient presented to the clinic with <u>complaints of a persistent cough</u> that began approximately one week ago. The cough is described as dry and occurs frequently throughout the day and night, <u>causing mild discomfort</u> but not resulting in any sleep disturbances. <u>There was no associated fever</u>, body chills, or night sweats reported. <u>The patient denies experiencing any shortness of breath, chest pain</u>, or any significant change in daily activities and energy levels. No noticeable exacerbating or relieving factors for the cough have been identified. The patient has <u>no recent history of travel, upper respiratory infections</u>, or known exposure to pollutants or irritants.	The patient presents with a two-day history of <u>an irritating cough, which has progressively worsened</u>. Alongside the cough, the patient reports <u>significant nasal congestion and frequent rhinorrhea</u>. The patient states experiencing discomfort in the nasal passages and describes the cough as persisting and non-productive. <u>No dyspnea is reported at this time</u>. The patient also <u>notes a high fever, with chills and body aches</u>, which began yesterday and has been unrelenting. Over-the-counter antipyretic medications provided minimal relief for the fever. Recent exposures include workplace and family members who have had similar symptoms within the past week. No history of asthma or other chronic respiratory conditions.
SAMPLE PATIENT 2	
The patient reports <u>experiencing nasal congestion and rhinorrhea for the past five days</u>. They also describe having <u>a dry cough persisting during the same period</u>, with no presence of mucus production. <u>The patient denies any dyspnea</u> and has a history of smoking, which they note as being roughly one pack per day for several years. They have tried over-the-counter decongestants without significant relief.	

Hình 4.3. Mẫu văn bản y khoa không cấu trúc mô tả triệu chứng lâm sàng của bệnh nhân

Tập dữ liệu này sẽ được sử dụng để đánh giá khả năng suy diễn chẩn đoán viêm phổi dựa trên mô hình mạng Bayesian. Cụ thể, các phương pháp xử lý văn bản như biểu diễn dữ liệu bằng embedding BioLord2023 sẽ được áp dụng để chuyển đổi mô tả triệu chứng thành dạng số hóa, giúp mô hình có thể học và suy diễn hiệu quả hơn. Ngoài ra, kỹ thuật suy diễn nhả cũng được triển khai nhằm xác định mối quan hệ giữa triệu chứng lâm sàng với khả năng mắc viêm phổi hoặc nhiễm trùng đường hô hấp.

4.2. Giới thiệu môi trường, dữ liệu và quy trình thực nghiệm

Trong nghiên cứu này, mọi thực nghiệm sẽ được thực hiện trên thư viện Scikit-Learn dựa trên ngôn ngữ Python. Môi trường thực nghiệm được triển khai trên các máy tính có cấu hình Intel Core i9-13500H 2.6 GHz và hệ điều hành Windows 11. Tập dữ liệu được sử dụng trong nghiên cứu được trích xuất từ bài báo [16]. Cụ thể, dataset SynSUM bao gồm tổng cộng 10.000 mẫu dữ liệu, trong đó có tổng cộng 13 cột, trong đó có 2 cột nhãn quan trọng là "pneu" và "inf". Tỉ lệ chia dữ liệu tuân theo tiêu chuẩn 80%-20%, với 80% mẫu dữ liệu đầu tiên dùng để huấn luyện và 20% còn lại phục vụ cho quá trình kiểm tra mô hình.

Các thí nghiệm được thiết kế nhằm đánh giá hiệu suất của các mô hình khác nhau trong việc chẩn đoán bệnh từ dữ liệu tổng hợp (SynSum Dataset) như trên bảng 4.4. Cụ thể, bảy nhóm thực nghiệm đã được triển khai để kiểm tra khả năng suy luận và trích xuất triệu chứng từ văn bản y khoa cũng như hiệu suất chẩn đoán dựa trên các phương pháp học máy và mô hình mạng Bayesian.

Bảng 4.4. Quy trình thực nghiệm

Thực nghiệm	Model	Input	Mục đích
1	- Bayesian Baseline Network	SynSum Dataset (Season / Season + Clinical + Symptoms)	Khả năng dự đoán của mô hình BN trong điều kiện mất cân bằng.
2	- XGBoost - SVM - Random Forest - NN	SynSum Dataset (Season + Clinical + Symptoms)	So sánh giữa các mô hình máy học truyền thống và BN
3	- Neural Network	Synsum Dataset	Khả năng dự đoán của mô hình Neural Network dựa trên các thuộc tính và văn bản y khoa
4	- XGBoost - SVM - Random Forest	Synsum Dataset (Text)	So sánh khả năng trích xuất triệu chứng trong văn bản y khoa của các mô hình học máy

	- Neural Network (FNN).		
5	- BN - XGBoost - BN - SVM - BN - RF - BN - NN - (Clinical2Text)	SynSum Dataset (Clinical + Symptoms + Text)	So sánh các mô hình máy học sau khi trích xuất triệu chứng kết hợp Bayesian Network để chẩn đoán.
6	- LIME		Giải thích suy diễn chẩn đoán của mô hình trên cục bộ.
7	- SHAP		Giải thích suy diễn chẩn đoán của mô hình trên toàn cục.

Những thực nghiệm trên giúp đánh giá toàn diện các phương pháp tiếp cận khác nhau, từ Bayesian Network đến học sâu và các mô hình giải thích, nhằm cải thiện độ chính xác và tính minh bạch trong chẩn đoán bệnh từ văn bản y khoa.

4.3. Độ đo đánh giá hiệu suất mô hình

Trong quá trình thực nghiệm, nghiên cứu sẽ tiến hành so sánh hiệu suất của mạng Bayesian với các phương pháp học máy khác như XGBoost và mạng nơ-ron để xác định cách tiếp cận tối ưu nhất cho bài toán chẩn đoán viêm phổi.

Bảng kết quả so sánh hiệu suất mô hình theo hai tiêu chí **ROC-AUC** và **AP**.

4.3.1. ROC-AUC

ROC-AUC (Receiver Operating Characteristic - Area Under the Curve) là một thước đo đánh giá hiệu suất của mô hình phân loại. Công thức tính ROC-AUC dựa trên đường cong ROC, phản ánh mối quan hệ giữa tỷ lệ dương tính thực sự (True Positive Rate - TPR) và tỷ lệ dương tính giả (False Positive Rate - FPR).

Chỉ số TPR và FPR:

- Tỷ lệ dương tính thực sự (TPR - Sensitivity/Recall): $TPR = \frac{TP}{TP + FN}$
- Tỷ lệ dương tính giả: $FPR = \frac{FP}{FP + TN}$

Trong đó:

- True Positive (TP): Số mẫu thực sự là pneumonia và được mô hình dự đoán

đúng.

- False Positive (FP): Số mẫu không phải pneu nhưng bị mô hình dự đoán nhầm là pneu/inf.
- True Negative (TN): Số mẫu không phải pneu và được mô hình dự đoán đúng.
- False Negative (FN): Số mẫu thực sự là pneu nhưng bị mô hình dự đoán nhầm thành không phải pneu.

ROC-AUC là diện tích dưới đường cong ROC, được tính bằng cách lấy tích phân của đường cong ROC hoặc bằng tổng diện tích của các hình chữ nhật/phần tam giác dưới đường cong.

Giá trị cao (gần 1): Mô hình có khả năng phân loại tốt.

Giá trị thấp (gần 0.5): Mô hình gần như phân loại ngẫu nhiên.

4.3.2. AP

Precision và Recall là hai thước đo quan trọng để đánh giá mô hình phân loại, đặc biệt trong bài toán chẩn đoán viêm phổi (pneu). Average Precision (AP) là một chỉ số tổng hợp đánh giá hiệu suất mô hình trên toàn bộ miền ngưỡng dự đoán.

Precision (Độ chính xác dương tính):
$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong đó:

- TP (True Positive): Số mẫu thực sự là pneu và được mô hình dự đoán đúng.
- FP (False Positive): Số mẫu không phải pneu nhưng bị mô hình dự đoán nhầm là pneu.

Recall (Độ phủ dương tính):
$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong đó:

- FN (False Negative): Số mẫu thực sự là pneu nhưng bị mô hình dự đoán nhầm thành không pneu.

Precision đo lường mức độ chính xác của các dự đoán dương tính, tức là trong tất cả các trường hợp mô hình dự đoán pneu, bao nhiêu phần trăm là đúng.

Recall đo lường khả năng phát hiện bệnh của mô hình, tức là trong tất cả các trường hợp thực sự mắc pneu, mô hình tìm ra được bao nhiêu.

Average Precision (AP) là diện tích dưới đường cong Precision-Recall (PR Curve), được tính bằng phương pháp tổng thang đo (Trapezoidal Rule):

$$AP = \sum_{i=1}^{n-1} (Recall_{i+1} - Recall_i) \times Precision_{i+1}$$

AP cao: Mô hình ít bỏ sót bệnh nhân viêm phổi (giảm FNs) và ít chẩn đoán nhầm (giảm FPs).

Ứng dụng: Hữu ích khi dữ liệu mất cân bằng (số bệnh nhân viêm phổi ít hơn nhiều so với không mắc bệnh), vì Precision-Recall đánh giá tốt hơn so với ROC trong trường hợp này.

4.4. Thực nghiệm 1: Mô hình Bayesian Baseline Network

Thực nghiệm 1 sử dụng mô hình Bayesian Network (BN) để đánh giá khả năng dự đoán của mô hình BN trong điều kiện mất cân bằng dữ liệu. Đầu vào của mô hình bao gồm các biến về mùa (Season), thông tin lâm sàng (Clinical) và triệu chứng (Symptoms).

Bảng 4.5: Kết quả thực nghiệm mô hình BBN

STT	Input	Pneumonia		Infection	
		ROC - AUC	AP	ROC - AUC	AP
1	Season	0.62	0.32	0.81	0.70
2	Season + Clinical + Symptoms	0.98	0.67	0.92	0.81

Khi chỉ sử dụng Season, hiệu suất dự đoán viêm phổi ROC-AUC = 0.62 và Precision Call thấp (0.32), cho thấy chỉ dựa vào mùa không đủ mạnh để dự đoán bệnh.

Tuy nhiên, dự đoán nhiễm trùng (Infection) có ROC-AUC = 0.81, cao hơn so với viêm phổi. Điều này có thể phản ánh rằng một số bệnh nhiễm trùng có tính mùa rõ rệt hơn viêm phổi.

Khi kết hợp Season + Clinical + Symptoms, hiệu suất cải thiện rõ rệt:

- Viêm phổi: ROC-AUC tăng lên 0.98, Precision Call tăng lên 0.67.
- Nhiễm trùng: ROC-AUC tăng lên 0.92, Precision Call tăng lên 0.81.

Điều này chứng minh rằng việc bổ sung dữ liệu lâm sàng và triệu chứng giúp tăng cường khả năng phân biệt bệnh tật của mô hình.

Sự cải thiện hiệu suất khi thêm Clinical + Symptoms chứng minh rằng phương pháp học có giám sát kết hợp với tri thức y khoa có thể giúp cải thiện chẩn đoán bệnh.

Chỉ sử dụng "Season" không đủ mạnh để dự đoán viêm phổi hoặc nhiễm trùng.

Bổ sung dữ liệu triệu chứng và lâm sàng giúp tăng hiệu suất đáng kể, từ mức trung bình (0.62 ROC-AUC) lên gần như hoàn hảo (0.98 ROC-AUC).

Mô hình Bayesian Network có tiềm năng ứng dụng cao trong chẩn đoán y khoa, đặc biệt khi có sự kết hợp giữa dữ liệu thực nghiệm và tri thức chuyên môn.

4.5. Thực nghiệm 2: So sánh BBN với mô hình khác

Thực nghiệm 2 so sánh hiệu suất giữa các mô hình học máy truyền thống, bao gồm XGBoost, SVM, Random Forest và mạng nơ-ron nhân tạo (NN), với mô hình Bayesian Network. Dữ liệu đầu vào vẫn giữ nguyên như thực nghiệm 1 nhằm đảm bảo tính nhất quán trong đánh giá.

Bảng 4.6: So sánh mô hình BBN với các mô hình truyền thống.

STT	Model	Input	Pneumonia		Infection	
			ROC - AUC	AP	ROC - AUC	AP
1	XGBoost		0.78	0.55	0.89	0.85
2	SVM	Season	0.78	0.56	0.89	0.85
3	RF	+ Clinical	0.62	0.35	0.89	0.85
4	NN	+ Symptoms	0.95	0.44	0.95	0.88
5	BBN		0.98	0.67	0.92	0.81

Bảng 4.6 trình bày kết quả thực nghiệm so sánh giữa mô hình Bayesian Baseline Network (BBN) với ba thuật toán truyền thống là XGBoost, SVM, Neural Network (NN) và Random Forest (RF).

Có thể thấy rằng, BNN vượt trội hoàn toàn về cả hai tiêu chí ROC-AUC và Precision-Call (Average Precision - AP) trong chẩn đoán viêm phổi với ROC-AUC đạt 0.98 và AP đạt 0.67, cao hơn đáng kể so với các mô hình khác (dao động từ 0.62 đến 0.78 về ROC-AUC và từ 0.35 đến 0.56 về AP).

Đối với nhiệm vụ chẩn đoán nhiễm trùng, BNN tiếp tục duy trì hiệu suất cao với ROC-AUC đạt 0.92 và AP đạt 0.81, nhỉnh hơn so với các mô hình truyền thống ngoại trừ Neural Network có nhỉnh hơn.

Kết quả thực nghiệm này cho thấy BNN có khả năng học tốt từ dữ liệu mất cân bằng nhãn nhờ vào việc mô hình có thể đánh giá được mức độ chắc chắn trong dự đoán và học theo cách phản ánh đúng xác suất xảy ra của các nhãn.. Nhờ đó, mô hình không chỉ đạt độ chính xác cao mà còn giảm thiểu hiện tượng lệch nhãn, từ đó khẳng định tiềm năng ứng dụng của Bayesian Neural Network trong các bài toán chẩn đoán y khoa phức tạp, nơi dữ liệu thường khan hiếm và mất cân bằng nghiêm trọng.

4.6. Thực nghiệm 3: Mô hình Neural Network

Thực nghiệm 3 kiểm tra khả năng dự đoán của mô hình Neural Network khi sử dụng đồng thời cả dữ liệu thuộc tính và văn bản y khoa.

Bảng 4.7: Kết quả thực nghiệm mô hình Neural Network

STT	Input	Pneumonia		Infection	
		ROC - AUC	AP	ROC - AUC	AP
1	Clinical	0.61	0.01	0.81	0.44
2	Symptoms	0.91	0.30	0.90	0.75
3	Clinical + Symptoms	0.95	0.44	0.95	0.88
4	Text	0.94	0.23	0.91	0.79
5	Clinical + Text	0.95	0.29	0.94	0.83
6	Clinical + Symptoms + Text	0.95	0.54	0.95	0.88

▪ **Hiệu suất chẩn đoán viêm phổi (Pneu)**

- Mô hình sử dụng Clinical đơn lẻ có hiệu suất rất thấp với ROC-AUC chỉ 0.61 và AP là 0.01, cho thấy thông tin lâm sàng nền (như COPD, hen suyễn) không đủ mạnh để phân biệt bệnh nhân viêm phổi.
- Trong khi đó, **Symptoms** cho kết quả khả quan hơn đáng kể với AUC 0.91 và AP 0.3, phản ánh rằng các triệu chứng (ho, khó thở, đau ngực, v.v.) là **đặc trưng quan trọng cho việc chẩn đoán viêm phổi**.
- Khi kết hợp Clinical + Symptoms, mô hình đạt hiệu suất tối ưu với ROC-AUC 0.95, AP tăng lên 0.54, chứng minh rằng việc bổ sung thông tin nền vào triệu chứng giúp tăng tính đặc hiệu và chính xác.
- Đáng chú ý, mô hình chỉ dùng Text (embedding từ BioLord) cũng đạt AUC 0.94, cho thấy khả năng trích xuất triệu chứng hiệu quả từ văn bản tự do.
- Hai tổ hợp đầu vào gồm Clinical + Text và Clinical + Symptoms + Text đều đạt AUC 0.95, tuy nhiên mô hình tích hợp cả ba nguồn dữ liệu cho kết quả tốt nhất về AP (0.54), phản ánh khả năng phân biệt cao và ổn định khi xử lý tình huống mất cân bằng nhãn.

▪ **Hiệu suất chẩn đoán nhiễm trùng (Inf)**

- Trái ngược với viêm phổi, mô hình sử dụng Clinical riêng lẻ đã đạt hiệu suất khá với AUC 0.81 và AP 0.44, cho thấy nhiễm trùng có thể liên quan nhiều đến các yếu tố nền như hút thuốc, bệnh nền.
- Symptoms vẫn tiếp tục thể hiện vai trò quan trọng với AUC 0.9, AP 0.75.
- Mô hình tích hợp Clinical + Symptoms tiếp tục vượt trội (AUC 0.95, AP 0.88), tương đương với tổ hợp Clinical + Symptoms + Text, cho thấy việc thêm text không làm tăng đáng kể hiệu suất nhưng có thể giúp tăng tính khái quát của mô hình.
- Mô hình Text đơn lẻ và Clinical + Text cho kết quả đồng đều với AUC ~0.91–0.92, phản ánh rằng văn bản tự nhiên có thể thay thế hoặc hỗ trợ vai trò của triệu chứng cấu trúc.

▪ **Các kết quả cho thấy:**

Triệu chứng (dù được trích xuất hay cấu trúc) là yếu tố quyết định trong chẩn đoán viêm phổi và nhiễm trùng.

Văn bản tự do có thể được khai thác hiệu quả thông qua embedding (như BioLord), với hiệu suất gần tương đương dữ liệu cấu trúc.

Việc kết hợp ba nguồn dữ liệu (Clinical + Symptoms + Text) đem lại mô hình ổn định, có khả năng học tốt trên dữ liệu phức tạp và không đồng nhất.

Đặc biệt, các giá trị AP thấp ở mô hình đơn lẻ (như Clinical) cho thấy tầm quan trọng của việc xử lý dữ liệu mất cân bằng – một vấn đề thực tiễn trong chẩn đoán bệnh.

Những kết quả này là tiền đề cho việc đánh giá các mô hình thay thế mạng FNN bằng các thuật toán như XGBoost hoặc SVM trong nhiệm vụ trích xuất triệu chứng từ text, đồng thời tích hợp với các pipeline mạng Bayes để nâng cao độ chính xác và khả năng suy luận minh bạch trong chẩn đoán bệnh.

4.7. Thực nghiệm 4: Trích xuất triệu chứng trong văn bản y khoa

Thực nghiệm 4 tập trung vào bài toán trích xuất triệu chứng từ văn bản y khoa. Mục tiêu của thực nghiệm này là đánh giá độ chính xác của từng mô hình trong việc

chuyển đổi văn bản thành thông tin có cấu trúc phục vụ chẩn đoán.

Bảng 4.8 cho thấy hiệu suất của bốn mô hình khác nhau: XGBoost, SVM, Random Forest và Neural Network trong việc trích xuất các triệu chứng Dyspnea, Cough, Pain, Fever và Nossal dựa trên các chỉ số Precision, Recall, F1-Score và Accuracy.

Bảng 4.8: Kết quả thực nghiệm khả năng trích xuất triệu chứng từ text của các thuật toán

STT	Model	Symptoms	Performance metrics			
			Precision	Recall	F1-Score	Accuracy
1	XGBoost	Dyspnea	0.96	0.88	0.92	0.97
		Cough	0.96	0.93	0.94	0.96
		Pain	0.94	0.60	0.73	0.93
		Fever	0.91	0.91	0.90	0.91
		Nossal	0.95	0.89	0.92	0.96
2	SVM	Dyspnea	0.97	0.92	0.95	0.98
		Cough	0.98	0.94	0.96	0.97
		Pain	0.98	0.64	0.78	0.94
		Fever	0.94	0.94	0.94	0.94
		Nossal	0.98	0.92	0.95	0.97
3	Random Forest	Dyspnea	0.95	0.77	0.85	0.94
		Cough	0.89	0.88	0.88	0.92
		Pain	0.96	0.34	0.50	0.90
		Fever	0.87	0.86	0.87	0.86
		Nossal	0.96	0.80	0.88	0.94
4	Neural Network	Dyspnea	0.88	0.96	0.92	0.96
		Cough	0.95	0.96	0.96	0.97
		Pain	0.69	0.77	0.73	0.92
		Fever	0.60	0.77	0.68	0.77
		Nossal	0.95	0.92	0.93	0.96

▪ **XGBoost:**

- Mô hình này đạt hiệu suất tương đối cao trên hầu hết các triệu chứng với Precision dao động từ 0.91 đến 0.96, Recall từ 0.60 đến 0.93 và Accuracy cao nhất là 0.97.
- Tuy nhiên, nhược điểm lớn nhất của XGBoost là Recall cho Pain chỉ đạt 0.60, khiến F1-Score giảm xuống còn 0.73. Điều này cho thấy mô hình không hoạt động tốt trong việc nhận diện triệu chứng Pain, ảnh hưởng đến hiệu suất tổng thể.

▪ **SVM:**

- SVM có Precision cao nhất trong tất cả các mô hình, dao động từ 0.94 đến 0.98. Quan trọng hơn, Recall của SVM cũng rất ổn định, đặc biệt là với Fever (0.94) và Nassal (0.92).
- Với F1-Score đạt 0.96 cho Cough và 0.95 cho Dyspnea, SVM có sự cân bằng tốt giữa Precision và Recall. Nhờ vậy, mô hình này đạt được độ chính xác cao nhất (0.98) trong toàn bộ dữ liệu, cho thấy khả năng phân loại vượt trội.

▪ **Random Forest:**

- Random Forest có độ chính xác thấp hơn so với SVM và XGBoost. Precision của mô hình này biến động từ 0.87 đến 0.96, nhưng Recall của triệu chứng Pain lại rất thấp (0.34), kéo theo F1-Score giảm xuống chỉ còn 0.50.
- Điều này cho thấy mô hình gặp khó khăn khi trích xuất thông tin từ dữ liệu, đặc biệt là các triệu chứng khó nhận diện.

▪ **Neural Network:**

- Neural Network thể hiện hiệu suất ấn tượng với Recall cao nhất cho Dyspnea (0.96) và Cough (0.96), đồng thời đạt F1-Score cao nhất cho hai triệu chứng này (0.92 và 0.96). Mặc dù Precision của Pain không cao (0.69), Recall của triệu chứng này đạt 0.77, giúp cân bằng hiệu suất tổng thể.
- Mô hình cũng có khả năng nhận diện triệu chứng Nassal tốt (Precision 0.95, Recall 0.92). Điều này cho thấy Neural Network có thể học được những đặc điểm phức tạp từ dữ liệu và có tiềm năng cao để cải thiện hơn nữa.

Dựa trên kết quả phân tích, **SVM và Neural Network** là hai mô hình tiềm năng nhất cho nhiệm vụ trích xuất triệu chứng. SVM có hiệu suất ổn định, đặc biệt là Precision cao, giúp giảm thiểu các trường hợp dương tính giả. Neural Network có ưu điểm ở khả năng học sâu từ dữ liệu, thể hiện qua Recall cao đối với các triệu chứng quan trọng. Do đó, hai mô hình này xứng đáng được tiếp tục nghiên cứu và cải thiện để đạt hiệu suất tối ưu trong thực tế.

4.8. Thực nghiệm 5: Kết hợp các mô hình trích xuất triệu chứng trong văn bản y khoa và Bayesian Network

Thực nghiệm 5 tiến hành so sánh hiệu suất giữa các mô hình học máy truyền thống sau khi kết hợp với mạng Bayesian. Cụ thể, các mô hình BN-XGBoost, BN-SVM, BN-RF và BN-NN được triển khai nhằm đánh giá lợi ích của việc tích hợp phương pháp suy luận xác suất với học sâu và học máy. Các đầu vào bao gồm dữ liệu lâm sàng, triệu chứng và văn bản đã được trích xuất.

Bảng 4.9: Kết quả thực nghiệm mô hình BN - Neural Network và so sánh các mô hình khác

STT	Model	Input	Pneumonia		Infection	
			ROC - AUC	AP	ROC - AUC	AP
1	BN - XGBoost	Clinical Text	0.85	0.11	0.91	0.79
2	BN - SVM		0.90	0.13	0.91	0.79
3	BN - RF		0.80	0.04	0.90	0.74
4	BN – NN (Clinical2Text)		0.95	0.39	0.92	0.78

Bảng 4.9 trình bày hiệu suất của bốn mô hình kết hợp giữa BN và các thuật toán học máy khác nhau sau khi trích xuất triệu chứng từ văn bản, truyền vào cấu trúc suy luận xác suất của mạng Bayes để chẩn đoán viêm phổi (Pneumonia) và nhiễm trùng (Infection). Các thuật toán được so sánh gồm: XGBoost, SVM, Random Forest và Neural Network (FNN).

▪ Kết quả trên nhiệm vụ chẩn đoán viêm phổi (Pneu)

- BN + XGBoost đạt ROC-AUC 0.85, AP 0.11: kết quả khá tốt về khả năng phân loại nhưng AP thấp cho thấy mô hình gặp khó khăn với dữ liệu mất cân

bằng.

- BN + SVM cải thiện nhẹ AUC lên 0.9 và AP 0.13, phản ánh khả năng phân ranh tuyến tính tốt hơn, nhưng vẫn bị hạn chế trong việc định lượng xác suất chính xác.
- BN + Random Forest cho kết quả kém nhất với AUC 0.8 và AP 0.04, cho thấy mô hình khó khai thác đặc trưng ngữ nghĩa hiệu quả từ văn bản hoặc bị nhiễu khi áp dụng vào BN.
- BN + Neural Network là mô hình vượt trội nhất với AUC 0.95, AP 0.36, cho thấy mạng nơ-ron có khả năng học biểu diễn tốt hơn và tạo ra đầu ra giàu thông tin hơn cho tầng suy luận của mạng Bayes. Mức tăng rõ rệt của AP so với các mô hình khác chứng minh hiệu quả xử lý tình huống mất cân bằng nhãn.

▪ **Kết quả trên nhiệm vụ chẩn đoán nhiễm trùng (Inf)**

- Các mô hình có kết quả tương đối đồng đều về AUC, dao động trong khoảng 0.9–0.92, cho thấy các đặc trưng từ văn bản đều cung cấp thông tin có giá trị cho chẩn đoán nhiễm trùng.
- Về AP, cả XGBoost và SVM đạt giá trị khá cao (0.79), vượt hơn Random Forest (0.74), cho thấy khả năng khai thác tốt các biểu diễn đặc trưng của triệu chứng dạng text.
- Tuy nhiên, BN + Neural Network vẫn duy trì mức AUC 0.92 với AP 0.78, chỉ thấp hơn SVM một chút, nhưng lại thể hiện hiệu suất đồng đều và mạnh ở cả hai nhiệm vụ chẩn đoán.

▪ **Nhận định tổng quát**

Mô hình SVM thực nghiệm 4 đã cho hiệu suất tốt nhất trong các mô hình được so sánh. Tuy nhiên, khi kết hợp với Bayesian Network để suy luận chẩn đoán, hiệu suất của SVM lại giảm đáng kể trong chẩn đoán pneu (0.90, 0.13), thấp hơn so với BN-NN (0.95, 0.39).

Nguyên nhân chính có thể đến từ cách thức SVM xử lý dữ liệu và tính chất của Bayesian Network:

- SVM tối ưu hóa trên biên quyết định: SVM hoạt động tốt khi dữ liệu có ranh giới phân tách rõ ràng. Khi trích xuất 5 triệu chứng từ văn bản, mô hình có thể đã học được ranh giới rõ ràng để phân biệt Pneumonia và Infection, dẫn đến ROC-AUC cao.
- BN yêu cầu quan hệ xác suất mạnh: Bayesian Network không chỉ dựa trên ranh giới phân loại mà còn cần các xác suất có điều kiện giữa các biến. SVM không trực tiếp học quan hệ xác suất mà chỉ tìm siêu phẳng tối ưu, do đó, khi tích hợp vào BN, xác suất đầu ra của SVM có thể không phù hợp hoặc không phản ánh đúng quan hệ nhân quả giữa các đặc trưng, làm giảm hiệu - suất chung.
- NN tận dụng embedding và thông tin ngữ cảnh: Neural Network có khả năng học các biểu diễn liên tục (embedding) từ dữ liệu văn bản, giúp nắm bắt mối quan hệ phức tạp giữa triệu chứng và bệnh. Khi kết hợp với BN, các xác suất suy diễn từ embedding có thể phản ánh thực tế tốt hơn so với SVM, do đó BN-NN vẫn giữ được hiệu suất cao.

Tóm lại, mặc dù SVM có thể hoạt động tốt khi phân loại trực tiếp từ triệu chứng trích xuất, nhưng do thiếu tính liên tục và quan hệ xác suất rõ ràng, mô hình này kém hiệu quả hơn khi được kết hợp với Bayesian Network để suy luận bệnh lý.

Mặc dù SVM và XGBoost cũng cho kết quả khá cạnh tranh trên nhiệm vụ nhiễm trùng, chúng lại kém hơn đáng kể trên viêm phổi – cho thấy tính ổn định thấp hơn so với FNN.


Do đó, việc lựa chọn mô hình trích xuất phù hợp với từng nhiệm vụ y tế là rất quan trọng, và mạng nơ-ron hiện đang là lựa chọn tối ưu khi tích hợp với mô hình xác suất như mạng Bayes.

4.9. Thực nghiệm 6: Kết quả XAI thông qua kỹ thuật LIME

Nhằm giải thích và đánh giá quá trình ra quyết định của mô hình baseline trong chẩn đoán viêm phổi, nhóm áp dụng kỹ thuật suy diễn phổ biến là LIME. Mục tiêu của phần này là phân tích mức độ đóng góp của từng đặc trưng đầu vào đến kết quả chẩn đoán trong bốn trường hợp cụ thể: (1) mẫu Pneu dương tính được dự đoán

đúng, (2) mẫu Pneu âm tính được dự đoán đúng, (3) mẫu Inf dương tính được dự đoán đúng, và (4) mẫu Inf âm tính được dự đoán đúng.

▪ **Trường hợp 1:**



Hình 4.10. Kết quả thực nghiệm LIME với chẩn đoán Pneumonia = yes

Mô hình dự đoán bệnh nhân có 58% khả năng bị viêm phổi, cao hơn 42% khả năng không mắc. Dự đoán này dựa vào các đặc trưng đầu vào mà mô hình đã học từ dữ liệu huấn luyện.

Suy diễn chẩn đoán từ mô hình: Dựa trên kết quả LIME, ta có thể "lý giải" cách mô hình suy diễn ra chẩn đoán viêm phổi thông qua sự đóng góp của từng đặc trưng đầu vào:


- Đầu tiên, đặc trưng sốt (fever) với giá trị quan sát cao (2.0) đóng vai trò như một triệu chứng điển hình của viêm phổi, góp phần đáng kể vào việc tăng xác suất dự đoán (+0.10).
- Tiếp theo, triệu chứng đau (pain) với giá trị 1.0 phản ánh tình trạng viêm hoặc nhiễm trùng, cũng góp phần tăng xác suất dự đoán (+0.09).
- Tương tự, triệu chứng ho (cough), với giá trị 1.0, là một dấu hiệu đặc trưng khác của viêm phổi, dù mức độ ảnh hưởng nhỏ hơn (+0.05).
- Một đặc trưng đáng chú ý là hen suyễn (asthma), tuy có thể gây nhầm lẫn với triệu chứng của viêm phổi, nhưng mô hình đã học được rằng trong bối cảnh dữ liệu hiện tại, asthma có mối liên hệ với viêm phổi và do đó góp phần làm tăng xác suất (+0.07).
- Ngược lại, việc không mắc bệnh phổi tắc nghẽn mạn tính (COPD) – được biểu hiện bởi giá trị quan sát là 0.0 – làm giảm mạnh xác suất bị viêm phổi

(−0.15), do mô hình học rằng sự hiện diện của COPD thường đi kèm với viêm phổi trong dữ liệu huấn luyện.

- Các đặc trưng còn lại như viêm mũi (nasal), viêm (inf), sốt mùa (hay_fever), hút thuốc (smoking) và khó thở (dyspnea) đều có giá trị quan sát bằng 0.0 và do đó hầu như không đóng góp đáng kể vào quyết định chẩn đoán trong trường hợp này.

Suy luận tổng quát hóa mô hình: Các đặc trưng như sốt, đau và ho là tín hiệu mạnh cho viêm phổi. Không mắc các bệnh lý nền như COPD, hen suyễn, hay sốt mùa (hay fever) có thể giảm xác suất mắc viêm phổi. Tuy nhiên, mô hình học từ dữ liệu nên có thể suy diễn ngược với kiến thức y khoa ở một số điểm nhỏ – đó là lúc cần chuyên gia y tế xem xét lại.

▪ Trường hợp 2:



Hình 4.11. Kết quả thực nghiệm LIME với chẩn đoán *Pneumonia* = no


Trong trường hợp hình 4.11, cho thấy mô hình dự đoán bệnh nhân không mắc viêm phổi với xác suất cao (0.74).

- Các đặc trưng lâm sàng có vai trò chính trong việc hỗ trợ chẩn đoán âm tính bao gồm: asthma, hay fever, smoking, COPD, inf, và pain, tất cả đều có giá trị quan sát là 0.0, đồng nghĩa với việc bệnh nhân không có những biểu hiện lâm sàng này. Mô hình đã học được rằng việc không mắc các tình trạng này làm giảm khả năng viêm phổi, từ đó góp phần tăng xác suất dự đoán không viêm phổi.
- Ngoài ra, một số đặc trưng như nasal, winter, và cough có giá trị quan sát bằng 1.0 (tức là bệnh nhân có những biểu hiện này), nhưng chúng lại không

đóng vai trò mạnh mẽ trong việc hướng mô hình đến dự đoán dương tính với viêm phổi.

- Đáng chú ý, sốt (fever) có giá trị 2.0 – vốn là một đặc trưng gợi ý mạnh đến viêm phổi – song trong trường hợp này lại không đủ để thay đổi dự đoán tổng thể của mô hình do các đặc trưng khác nghiêng nhiều về khả năng không mắc viêm phổi.

▪ Trường hợp 3:



Hình 4.12. Kết quả thực nghiệm LIME với chẩn đoán Infection = yes


Trong trường hợp hình 4.12, mô hình đưa ra dự đoán bệnh nhân có khả năng nhiễm trùng với xác suất 58%.

- Cough = 1.0: Đây là đặc trưng có đóng góp mạnh nhất vào việc tăng xác suất mắc nhiễm trùng (+0.35). Điều này phản ánh sự liên kết mạnh giữa triệu chứng ho và các bệnh nhiễm trùng đường hô hấp.
- Mùa hè (winter = 0): Đặc trưng này đóng góp đáng kể (+0.35), cho thấy mô hình học được mối liên hệ dịch tễ học – mùa hè thường là thời điểm giảm các ca nhiễm trùng.
- COPD = 1.0: Bệnh phổi tắc nghẽn mạn tính được nhận diện là một yếu tố nền có thể làm tăng nguy cơ nhiễm trùng (đặc biệt là nhiễm khuẩn hô hấp), đóng góp khoảng +0.08 vào xác suất dự đoán.
- Các đặc trưng khác như sốt (fever), hen suyễn (asthma), hút thuốc (smoking) có giá trị gần bằng 0 và đóng vai trò trung tính hoặc rất nhỏ.

Mô hình quyết định theo hướng chẩn đoán nhiễm trùng chủ yếu dựa trên sự hiện diện đồng thời của triệu chứng ho, mùa và có tiền sử COPD. Việc thiếu vắng

các đặc trưng “âm tính mạnh” như đau, sốt hay hen suyễn không đủ để lật ngược quyết định.

▪ **Trường hợp 4:**



Hình 4.13. Kết quả thực nghiệm LIME với chẩn đoán Infection = no

Ở trường hợp hình 4.13, mô hình đưa ra kết luận rằng bệnh nhân không mắc nhiễm trùng, với xác suất rất cao 78%. Dưới đây là các yếu tố then chốt dẫn đến quyết định này:


- Không ho (cough = 0.0): Đây là yếu tố làm giảm mạnh xác suất mắc bệnh (-0.39). Việc không xuất hiện triệu chứng ho được mô hình xem là bằng chứng quan trọng cho việc loại trừ khả năng nhiễm trùng.
- Không bị đau (pain = 0.0): Tương tự, đặc trưng này có đóng góp giảm xác suất đáng kể (-0.09), vì đau thường liên quan đến phản ứng viêm, nhiễm.
- Không bị hay fever, và không có triệu chứng ho (Dysp) đều góp phần giảm nhẹ thêm xác suất nhiễm trùng, thể hiện qua các đóng góp từ -0.07 đến -0.03. Đây đều là các yếu tố nguy cơ khi có mặt, và sự vắng mặt của chúng hỗ trợ cho kết luận âm tính.
- Mùa đông (winter = 1.0) là đặc trưng duy nhất có đóng góp tích cực (+0.29), thể hiện vai trò môi trường có nguy cơ, nhưng không đủ để bù lại các yếu tố âm tính mạnh khác.
- Không có sốt (fever = 0.0), khó thở (dysp = 0.0), nasal (nasal = 0.0) gần như không đóng góp vào quyết định, cho thấy mô hình không gán trọng số cao cho các đặc trưng này trong trường hợp này.

Tổng kết, quyết định chẩn đoán âm tính với nhiễm trùng được thúc đẩy bởi sự

thiếu vắng các triệu chứng lâm sàng đặc trưng như ho, đau, và các yếu tố nền như COPD hay hen suyễn. Đây là ví dụ điển hình cho cách LIME cho phép suy luận ngược, tức là từ sự không hiện diện của đặc trưng để khẳng định khả năng không mắc bệnh.

4.10. Thực nghiệm 7: Kết quả XAI thông qua kỹ thuật SHAP

4.10.1. Pneumonia



Hình 4.14. Kết quả thực nghiệm SHAP với chẩn đoán của nhân Pneumonia

Biểu đồ SHAP được trình bày ở Hình 4.14 thể hiện tác động của các đặc trưng lên đầu ra mô hình, trong đó:

- Trục hoành thể hiện giá trị SHAP: Độ ảnh hưởng của đặc trưng lên xác suất dự đoán viêm phổi)
- Trục tung liệt kê danh sách các đặc trưng được mô hình sử dụng. Mỗi điểm trong biểu đồ đại diện cho một bệnh nhân, được tô màu theo giá trị của đặc trưng tương ứng (đỏ: giá trị cao, xanh: giá trị thấp).

Từ biểu đồ này, có thể đưa ra một số suy diễn quan trọng:

1. Fever (sốt) là đặc trưng có ảnh hưởng mạnh nhất

Giá trị SHAP của đặc trưng fever dao động rộng và phần lớn nghiêng về

phía dương, cho thấy khi bệnh nhân có sốt (giá trị cao), mô hình có xu hướng tăng xác suất dự đoán viêm phổi. Điều này phù hợp với lâm sàng, vì sốt là một biểu hiện phổ biến và đặc trưng của viêm nhiễm đường hô hấp, đặc biệt là viêm phổi. Các điểm màu đỏ (giá trị sốt cao) tập trung nhiều ở vùng SHAP dương, xác nhận vai trò quan trọng của đặc trưng này trong chẩn đoán.

2. Cough (ho) và Dyspnea (khó thở) cũng là các yếu tố quan trọng

Cả hai đặc trưng này đều có giá trị SHAP lớn, đặc biệt là khi giá trị đặc trưng cao (đỏ), chúng góp phần làm tăng xác suất dự đoán. Khó thở và ho là các triệu chứng phổ biến ở bệnh nhân viêm phổi, và việc mô hình học được điều này chứng tỏ nó có khả năng nắm bắt mối liên hệ giữa đặc điểm lâm sàng và bệnh lý thực sự.

3. Vai trò của các yếu tố nguy cơ nền: smoking, asthma, COPD

Các yếu tố nền như hút thuốc (smoking), hen suyễn (asthma) và bệnh phổi tắc nghẽn mạn tính (COPD) cũng có ảnh hưởng, tuy nhỏ hơn so với triệu chứng cấp tính. Đặc biệt, khi giá trị smoking cao, một số điểm có SHAP dương, cho thấy hút thuốc có thể làm tăng khả năng viêm phổi do suy giảm hệ miễn dịch tại phổi. Tuy nhiên, do đây là yếu tố nền nên giá trị SHAP không quá lớn, phù hợp với kỳ vọng lâm sàng.

4. Ảnh hưởng của mùa đông (winter) và nhiễm trùng (inf)

Hai đặc trưng winter và inf cho thấy mức ảnh hưởng trung bình. Dễ nhận thấy rằng vào mùa đông, xác suất mắc các bệnh đường hô hấp thường cao hơn, nên yếu tố mùa có thể giúp mô hình điều chỉnh xác suất chẩn đoán. Đặc biệt, khi bệnh nhân có biểu hiện nhiễm trùng rõ (inf cao), giá trị SHAP thường nghiêng về dương, hỗ trợ quyết định chẩn đoán.

5. Các đặc trưng ít quan trọng hơn


Một số đặc trưng như nasal, hay_fever và pain có giá trị SHAP khá nhỏ, cho thấy tác động của chúng lên mô hình là tương đối yếu. Tuy nhiên, điều này không có nghĩa là chúng vô nghĩa, mà có thể trong tập dữ liệu này, chúng không mang tính phân biệt cao giữa bệnh nhân viêm phổi và không viêm phổi.

Phân tích SHAP cung cấp cái nhìn sâu sắc về cách mô hình học máy đưa ra

quyết định chẩn đoán viêm phổi. Các triệu chứng cấp tính như sốt, ho và khó thở là những đặc trưng có ảnh hưởng mạnh nhất, trong khi các yếu tố nền như hút thuốc hay hen suyễn góp phần bổ sung vào xác suất chẩn đoán.

4.10.2. Infection

Biểu đồ SHAP ở Hình 4.15 minh họa ảnh hưởng của 12 đặc trưng đến xác suất dự đoán nhân inf.



Hình 4.15. Kết quả thực nghiệm SHAP với chẩn đoán của nhân Infection

1. Cough (ho) và Winter (mùa đông): các chỉ dấu mạnh nhất

Trong biểu đồ, cough có phân bố SHAP rất rõ rệt: các mẫu có giá trị ho cao (đỏ) hầu như luôn làm tăng xác suất dự đoán inf, trong khi mẫu không ho (xanh) làm giảm khả năng này. Điều này phản ánh thực tế rằng ho là phản xạ phổ biến khi cơ thể có phản ứng viêm nhiễm đường hô hấp – đặc biệt là nhiễm trùng.

Tương tự, đặc trưng winter có vai trò quan trọng. Các mẫu bệnh nhân có giá trị winter cao (tức là đến khám vào mùa đông) thường đi kèm với SHAP dương, tức là mùa đông làm tăng xác suất dự đoán nhiễm trùng. Đây là kết quả phù hợp với dịch tễ học, vì mùa đông là thời điểm tỉ lệ mắc các bệnh truyền nhiễm đường hô hấp tăng cao do điều kiện khí hậu và mật độ tiếp xúc trong không gian kín.

2. *Smoking (hút thuốc), Pain (đau) và Asthma (hen suyễn): yếu tố nền góp phần tăng xác suất*

Đặc trưng smoking cho thấy vai trò đáng kể, với các điểm đỏ tập trung phía bên phải trục SHAP (giá trị dương), nghĩa là hút thuốc làm tăng xác suất bị nhiễm trùng. Điều này được giải thích do hút thuốc làm suy giảm khả năng miễn dịch tại phổi và tạo điều kiện cho vi sinh vật xâm nhập.

Pain và asthma cũng có tác động đáng kể: bệnh nhân có triệu chứng đau hoặc tiền sử hen suyễn (giá trị cao) thường có SHAP dương, nghĩa là các yếu tố này làm tăng xác suất mô hình dự đoán bệnh nhân bị nhiễm trùng. Hen suyễn có thể làm giảm hiệu quả hàng rào miễn dịch hô hấp, còn đau (nhất là đau ngực hoặc toàn thân) thường đi kèm với phản ứng viêm hệ thống.

3. *COPD và đặc trưng pneu (viêm phổi)*

COPD (bệnh phổi tắc nghẽn mạn tính) cũng thể hiện vai trò tương tự asthma, tuy với cường độ thấp hơn. Đặc biệt đáng chú ý là sự hiện diện của đặc trưng pneu – tức là người bệnh đã được xác định viêm phổi. Sự đóng góp SHAP của đặc trưng này đa phần là dương, phản ánh mối quan hệ gần gũi giữa viêm phổi và nhiễm trùng. Tuy nhiên, vì chẩn đoán viêm phổi không đồng nghĩa với nguyên nhân nhiễm trùng (ví dụ, có thể do hít phải vật lạ, viêm không do vi sinh), nên mức ảnh hưởng của pneu chỉ ở mức trung bình.

4. *Fever (sốt), Nasal (ngạt mũi), Hay_fever (viêm mũi dị ứng) và Dyspnea (khó thở)*


Bốn đặc trưng này có tác động nhỏ hơn đến dự đoán inf. Trong đó, fever – dù thường là chỉ dấu nhiễm trùng – lại không thể hiện rõ ràng như trong các mô hình chẩn đoán viêm phổi, có thể do mức độ phân bố sốt giữa các nhóm nhiễm trùng và không nhiễm không đủ chênh lệch. Nasal và hay_fever có ảnh hưởng rất nhỏ, có thể do mô hình nhận ra rằng các biểu hiện này thường liên quan đến dị ứng hoặc viêm mũi do nguyên nhân không nhiễm trùng.

Dyspnea – thường là biểu hiện ở giai đoạn tiến triển nặng – có giá trị SHAP xấp xỉ 0 ở hầu hết mẫu, cho thấy mô hình không dùng đặc trưng này để phân biệt

trạng thái nhiễm trùng ban đầu.

4.11. So sánh kết quả thực nghiệm SHAP giữa BlackBox và WhiteBox

Trong nghiên cứu này, nhóm thực hiện phân tích SHAP để đánh giá mức độ ảnh hưởng của các đặc trưng và độ hiệu quả trong hai mô hình chẩn đoán viêm phổi: Bayesian Network (WhiteBox) và Neural Network (BlackBox) như hình 4.16.



Hình 4.16. Kết quả thực nghiệm SHAP giữa hai mô hình WhiteBox và BlackBox

- **Chẩn đoán Pneumonia**

Đối với Bayesian Network, đặc trưng fever có ảnh hưởng lớn nhất với giá trị SHAP dao động trong khoảng $[-0.1, 0.4]$, chủ yếu có tác động dương đến dự đoán. Tiếp theo là cough, với giá trị SHAP nằm trong khoảng $[-0.2, 0.2]$.

Ngược lại, Neural Network cho thấy mức độ ảnh hưởng mạnh hơn của fever, với giá trị SHAP mở rộng đến 0.8, cao hơn đáng kể so với Bayesian Network. Đặc trưng cough cũng có tác động mạnh, với giá trị SHAP lên đến 0.4. Điều này cho thấy mô hình Neural Network có khả năng khuếch đại ảnh hưởng của một số đặc trưng nhất định.

- **Chẩn đoán Infection**

Bayesian Network xác định cough là đặc trưng quan trọng nhất với giá trị SHAP trong phạm vi $[-0.15, 0.4]$, tiếp theo là winter ($[-0.2, 0.25]$) và smoking ($[-0.2, 0.1]$). Điều này phản ánh tầm quan trọng của yếu tố môi trường và thói quen sinh hoạt đối với nguy cơ nhiễm trùng.

Neural Network lại đánh giá nasal là đặc trưng quan trọng nhất, với giá trị SHAP đạt 0.5, tiếp theo là winter (0.4) và cough (0.25). Điểm khác biệt này cho thấy mô hình Neural Network có thể học được các mối quan hệ phi tuyến tính giữa triệu chứng và bệnh, ví dụ như mối liên hệ giữa nghẹt mũi và nhiễm trùng.

- **So sánh tổng quan**

Dựa trên biểu đồ SHAP thu được trên hình 4.12, có thể thấy sự khác biệt rõ rệt giữa hai mô hình về mặt định lượng lẫn định tính.

Mô hình Bayesian thể hiện ảnh hưởng của các đặc trưng một cách chặt chẽ, đồng đều và dễ giải thích hơn, trong khi Neural Network có xu hướng tập trung mạnh vào một số đặc trưng cụ thể, thể hiện qua giá trị SHAP cao đột biến ở một vài yếu tố như nasal hay fever ở nhóm Infection. Điều này phản ánh đặc tính "hộp đen" của mạng nơ-ron, vốn khó kiểm soát và dễ bị thiên lệch khi mô hình hóa.

Một điểm quan trọng cần lưu ý là thời gian tính toán SHAP trên hai mô hình có sự khác biệt đáng kể. Khi thực hiện trên tập dữ liệu kiểm thử gồm 2000 mẫu, thời gian tính toán SHAP của Neural Network kéo dài hơn 14 tiếng, trong khi Bayesian

Network chỉ mất hơn 8 tiếng. Điều này cho thấy, ngoài khả năng giải thích tốt hơn, Bayesian Network còn giúp giảm thiểu chi phí tính toán trong việc phân tích SHAP, điều này đặc biệt quan trọng khi áp dụng trên các hệ thống thực tế với khối lượng dữ liệu lớn.

Từ các phân tích trên, có thể kết luận rằng Bayesian Network (WhiteBox) có lợi thế rõ ràng hơn so với Neural Network (BlackBox) trong việc diễn giải mô hình chẩn đoán bằng SHAP. Ngoài việc cung cấp thông tin rõ ràng và dễ hiểu hơn, Bayesian Network còn giúp tối ưu hóa thời gian tính toán SHAP, khiến nó trở thành lựa chọn phù hợp hơn trong các hệ thống hỗ trợ ra quyết định y khoa.

KẾT LUẬN VÀ KHUYẾN NGHỊ

Nghiên cứu này đã triển khai và đánh giá hiệu quả của mô hình Mạng Bayesian (BN) trong chẩn đoán viêm phổi trên tập dữ liệu mất cân bằng nhãn SynSum Dataset. BN cho thấy khả năng biểu diễn phân phối xác suất hậu nghiệm và hỗ trợ suy luận nhãn bệnh lý với mức độ tin cậy cao. Kết quả thực nghiệm chỉ ra rằng BN có thể khái quát tốt trong điều kiện dữ liệu thiếu hụt và mất cân bằng.

Ngoài ra, nghiên cứu đã phát triển và thử nghiệm mô hình Text2Clinical nhằm khai thác thông tin từ văn bản y khoa do bác sĩ ghi nhận. Việc tích hợp dữ liệu phi cấu trúc vào quá trình suy luận bệnh lý giúp cải thiện khả năng dự báo, tuy nhiên hiệu suất tổng thể chưa vượt trội so với các mô hình baseline.

Hướng nghiên cứu tiếp theo tập trung vào cải tiến phương pháp embedding văn bản y khoa, tối ưu hóa suy luận xác suất và phát triển kiến trúc mô hình phân tán. Một thách thức quan trọng là xử lý văn bản phi cấu trúc tiếng Việt, yêu cầu xây dựng hệ thống embedding y khoa chuyên biệt và nâng cao khả năng suy diễn trên dữ liệu lâm sàng.

TÀI LIỆU THAM KHẢO

- [1] S. Y. Xin, Mathematical foundations, in Introduction to Algorithms for Data Mining and Machine Learning, Academic Press, 2019, pp. 19–43.
- [2] D. Andy and A. M. Agogino, “Text analysis for constructing design representations,” *Artif. Intell. Eng.*, vol. 11, pp. 65–75, 1997.
- [3] C. E. Kahn Jr, L. M. Roberts, K. A. Shaffer, and P. Haddawy, “Construction of a Bayesian network for mammographic diagnosis of breast cancer,” *Comput. Biol. Med.*, vol. 27, pp. 19–29, 1997.
- [4] G. Paolo and F. Taroni, “Evaluation of scientific evidence using Bayesian networks,” *Forensic Sci. Int.*, vol. 125, pp. 149–155, 2002.
- [5] G. M. Bruce, S. H. Richard, G. R. Martin, M. M. Mary, and J. W. Michael, “Using Bayesian belief networks to evaluate fish and wildlife population viability under land management alternatives from an environmental impact statement,” *For. Ecol. Manage.*, vol. 153, pp. 29–42, 2001.
- [6] M. E. Borsuk, C. A. Stow, and K. H. Reckhow, “A Bayesian network of eutrophication models for synthesis, prediction, and uncertainty analysis,” *Ecol. Modell.*, vol. 173, pp. 219–239, 2004.
- [7] S. Wooldridge and T. Done, “Learning to predict large-scale coral bleaching from past events: A Bayesian approach using remotely sensed data, in-situ data, and environmental proxies,” *Coral Reefs*, vol. 23, pp. 96–108, 2004.
- [8] J. Bromley, N. A. Jackson, O. J. Clymer, A. M. Giacomello, and F. V. Jensen, “The use of Hugin® to develop Bayesian networks as an aid to integrated water resource planning,” *Environ. Modell. Software*, vol. 20, pp. 231–242, 2005.
- [9] HCMUE Journal of Science, INTERPRETATION OF CREDIT CARD FEATURES BY LIME AND SHAP AFTER DEEP LEARNING.
- [10] R. Guidotti, A. Monreale, S. Ruggieri, F. Turini, F. Giannotti, and D. Pedreschi, “A Survey of Methods for Interpreting Machine Learning Models,” *ACM Computing Surveys*, vol. 52, no. 5, pp. 1–52, 2020.
- [11] A. Gramegna and P. Giudici, “SHAP and LIME: An Evaluation of Discriminative Power in Credit Risk,” *Frontiers in Artificial Intelligence*, vol. 4,

Article 752558, 2021. [Online]. Available: <https://doi.org/10.3389/frai.2021.752558>

[12] W. S. Kanmani and B. Jayapradha, “Prediction of default customer in banking sector using artificial neural network,” *International Journal of Research in Information Technology and Computing*, vol. 5, pp. 293–296, 2017.

[13] S. M. Lundberg and S. I. Lee, “Explaining black box models with Shapley values,” in *Advances in Neural Information Processing Systems*, 2017, pp. 4765–4774.

[14] C. Molnar, *Interpretable Machine Learning*. Leanpub, 2020. [Online]. Available: <https://christophm.github.io/interpretable-ml-book/>

[15] Interpretable ML - Học máy khả diễn giải, HackMD. [Online]. Available: <https://hackmd.io/@ggBtfWNZRiqm5a1TONBR-g/HktbaP0Pu>. [Accessed: Mar. 19, 2025]

[16] P. Rabaey, H. Arno, S. Heytens, and T. Demeester, “SynSUM -- Synthetic Benchmark with Structured and Unstructured Medical Records,” *arXiv preprint arXiv:2409.08936*, 2024. [Online]. Available: <https://arxiv.org/abs/2409.08936>

[17] ML-pneu-research, GitHub repository. Available: <https://github.com/BaoTran019/ML-pneu-research>.

[18] E. H. Shortliffe, R. Davis, S. G. Axline, B. G. Buchanan, C. C. Green, and S. N. Cohen, “Computer-based consultations in clinical therapeutics: Explanation and rule acquisition capabilities of the MYCIN system,” *Computers and Biomedical Research*, vol. 8, no. 4, pp. 303–320, 1975.

[19] K. J. Cios, W. Pedrycz, and R. W. Swiniarski, *Data Mining Methods for Knowledge Discovery*, Boston, MA: Springer, 1998.

[20] P. J. F. Lucas, L. C. van der Gaag, and A. Abu-Hanna, “Bayesian networks in biomedicine and health-care,” *Artificial Intelligence in Medicine*, vol. 30, no. 3, pp. 201–214, 2004.

[21]. Hình 1.1 Available: <https://covid19.gov.vn>

[22] A. Zell, *Simulation Neuronaler Netze (Simulation of Neural Networks)*, 1st ed. Addison-Wesley, 1994, p. 73.

- [23] J. Schmidhuber, "Deep learning in neural networks: An overview," *Neural Networks*, vol. 61, pp. 85–117, Jan. 2015, doi: 10.1016/j.neunet.2014.09.003.
- [24] "Multi-layer Perceptron và Backpropagation," *Machine Learning Cơ Bản*, Feb. 24, 2017. [Online]. Available: <https://machinelearningcoban.com/2017/02/24/mlp/>. [Accessed: Mar. 31, 2025].

